

EM Algorithm

Expectation–Maximization 알고리즘

불완전 데이터 (incomplete data) 에서의 최대가능도 추정 (MLE)



Dempster, Laird & Rubin (1977) · GMM · Missing data · ABO 혈액형 · 회귀분석

목차

01

EM 알고리즘의 기본 개념

Missing data 와 MLE, 핵심 항등식

02

E-step 과 M-step

Q 함수, 지수족, minorize-maximize 관점

03

Example 1 · Gaussian Mixture

2-class 1 차원 정규혼합 : $\pi, \mu_1, \mu_2, \sigma_1, \sigma_2$

04

Example 2 · Bivariate Normal

결측이 있는 이변량 정규분포의 MLE

05

Example 3 · ABO 혈액형

Multinomial: phenotype $\rightarrow$ genotype

06

Example 4 · 회귀분석 (MLR)

반응변수 Y 가 결측인 경우

07

EM 의 성질과 장단점

Monotonicity, 수렴 속도, 표준오차

+

별도 슬라이드 : EM 의 확장

MCEM (수치적 E-step), 수치적 M-step

01

EM 알고리즘의 기본 개념

원래는 결측 (missing) 이 있는 데이터에서 MLE 를 계산하기 위한 알고리즘

EM 알고리즘이란 ?

- 직접 최대화하기 어려운 **likelihood** 를 반복 (iteration) 으로 최대화하는 알고리즘
- 관측되지 않은 부분 z 를 도입해 "**완전 데이터 (complete data)**" 를 상정 → 완전 데이터에서는 MLE 가 쉬움
- 두 단계를 번갈아 반복
 - **E-step:** 현재 추정치 $\theta^{(t)}$ 에서 완전 데이터 log-likelihood 의 조건부 기댓값 계산
 - **M-step:** 그 기댓값을 θ 에 대해 최대화 → $\theta^{(t+1)}$
- **Dempster, Laird & Rubin (1977, JRSS-B)** 이 일반적 형태로 정리하고 이름 붙임
 - 그 이전 : Hartley (1958), Baum et al. (1970, HMM), Orchard & Woodbury (1972), Sundberg (1974) 등

데이터 구조



$$x = (y, z)$$

관측 데이터 likelihood:

어렵다 (적분 / 합이 log 안에)

완전 데이터 likelihood:

쉽다 (보통 closed-form MLE)

원래 동기 : Missing data 가 있을 때의 MLE

관측 데이터 y 만으로 쓴 likelihood 는 결측 부분 z 를 적분 (합) 으로 없애야 함

$$L(\theta; y) = f(y; \theta) = \int f_c(y, z; \theta) dz$$

$$\ell(\theta) = \log \int f_c(y, z; \theta) dz$$

만약 z 도 관측되었다면 ...

$$\ell_c(\theta) = \log f_c(y, z; \theta)$$

핵심 아이디어

- $\log$ 안에 적분 (합) 이 있어 $\ell(\theta)$ 의 최대화는 대개 closed form 이 없음
- 모르는 z (정확히는 z 의 함수) 를 현재 추정치 $\theta^{(t)}$ 하에서의 **조건부 기댓값**으로 " 채우고 ", 완전 데이터 MLE 를 구한다
- 이를 반복 $\rightarrow$ 관측 데이터 likelihood $\ell(\theta)$ 의 (국소) 최대값으로 수렴

"missing" 의 넓은 의미

결측값

설문 무응답, 측정 누락

중도절단

censored / truncated data

혼합모형

각 관측치의 소속 class

Random effects

혼합모형의 random effect

유전학

관측 불가능한 genotype

HMM

숨겨진 상태열 (Baum-Welch)

핵심 항등식 : $\ell(\theta) = Q - H$

조건부 밀도 $k(z | y; \theta) = f_c(y, z; \theta) / f(y; \theta)$ 를 이용하면

$$f(y; \theta) = \frac{f_c(y, z; \theta)}{k(z | y; \theta)} \implies \ell(\theta) = \log f_c(y, z; \theta) - \log k(z | y; \theta)$$

양변을 $Z \sim k(z | y; \theta^{(t)})$ 에 대해 기댓값을 취하면 (좌변은 z 와 무관):

$$\ell(\theta) = Q(\theta | \theta^{(t)}) - H(\theta | \theta^{(t)})$$

Q

EM 이 실제로 계산 · 최대화하는 함수

$$Q(\theta | \theta^{(t)}) = E[\log f_c(y, Z; \theta) | y, \theta^{(t)}]$$

H

계산하지 않음 — monotonicity 증명에 사용


$$H(\theta | \theta^{(t)}) = E[\log k(Z | y; \theta) | y, \theta^{(t)}]$$

02

E-step 과 M-step

Q 함수의 계산 (Expectation) 과 최대화 (Maximization)

EM 알고리즘의 전체 흐름



E $Q(\theta | \theta^{(t)}) = \int \log f_c(y, z; \theta) k(z | y; \theta^{(t)}) dz$

M $\theta^{(t+1)} = \arg \max_{\theta} Q(\theta | \theta^{(t)})$

수렴 판정 (stopping rule)

$$\|\theta^{(t+1)} - \theta^{(t)}\| < \epsilon \quad \text{or} \quad |\ell(\theta^{(t+1)}) - \ell(\theta^{(t)})| < \epsilon$$

EM 은 수렴이 느릴 수 있으므로 상대 변화량 기준 + 최대 반복 수를 함께 사용

E-step 자세히 : 무엇을 계산하는가 ?

E $Q(\theta \mid \theta^{(t)}) = \int \log f_c(y, z; \theta) k(z \mid y; \theta^{(t)}) dz$

- 필요한 것 : 결측 z 의 **조건부 분포** $k(z \mid y; \theta^{(t)})$ — Bayes 정리

$$k(z \mid y; \theta^{(t)}) = \frac{f_c(y, z; \theta^{(t)})}{\int f_c(y, z'; \theta^{(t)}) dz'}$$

지수족 (exponential family) 이면 E-step 이 단순해진다

$$\log f_c(x; \theta) = \eta(\theta)^\top T(x) - A(\theta) + c(x)$$

$$Q(\theta \mid \theta^{(t)}) = \eta(\theta)^\top T^{(t)} - A(\theta) + \text{const}, \quad T^{(t)} = E[T(X) \mid y, \theta^{(t)}]$$

→ **E-step = 완전 데이터 충분통계량 $T(x)$ 의 조건부 기댓값 $T^{(t)}$ 계산**

주의 : "z 를 대입 " 하는 것이 아니다

채우는 것은 z 자체가 아니라 log-likelihood 에 들어가는 충분통계량 (z 의 함수) 의 기댓값이다 .

$$E[Z^2 \mid y] = (E[Z \mid y])^2 + \text{Var}(Z \mid y) \neq (E[Z \mid y])^2$$

예 : 정규분포에서 z^2 의 기댓값에는 조건부 분산이 더해져야 함 . 이를 빼먹으면 분산이 과소추정됨 (Example 2 참조).

혼합모형 · multinomial 처럼 ℓ_c 가 z 에 대해 선형이면 $E[z]$ 를 대입해도 동일

M-step 자세히 : 완전 데이터 MLE 를 다시 본다

M $\theta^{(t+1)} = \arg \max_{\theta} Q(\theta \mid \theta^{(t)})$

- 완전 데이터 MLE 와 **같은 형태** — 관측되지 않은 충분통계량 대신 그 기댓값 $T^{(t)}$ 를 사용
- 지수족이면 M-step 은 moment equation 을 푸는 것과 같다 :

$$E_{\theta}[T(X)] = T^{(t)} \implies \theta^{(t+1)}$$

- 많은 경우 closed form: 가중평균, 가중분산, 비율 (gene counting) 등
- 모수 제약조건 자동 만족 : $\boldsymbol{\pi} \in [0,1], \boldsymbol{\Sigma} \mathbf{p} = \mathbf{1}, \boldsymbol{\Sigma} > \mathbf{0}$
- closed form 이 없으면 수치적 최적화 필요 → **별도 슬라이드 (numerical M-step)**

GEM: Generalized EM


M-step 에서 Q 를 꼭 최대화할 필요는 없다 .
증가만 시키면 된다 :

$$Q(\theta^{(t+1)} \mid \theta^{(t)}) \geq Q(\theta^{(t)} \mid \theta^{(t)})$$

이 조건만 만족해도 $\ell(\theta^{(t)})$ 의 단조 증가 (monotonicity) 가 그대로 유지됨 .

예 : Newton 한 스텝 (EM gradient), 모수 블록별 조건부 최대화 (ECM)

Minorize-Maximize (MM) 관점



Example 1 데이터, μ_1 만 변화 (나머지 모수 고정)

Q 에 상수를 더한 함수 G_t 는 ℓ 의 하한 (minorizer)

$$G_t(\theta) = Q(\theta | \theta^{(t)}) - Q(\theta^{(t)} | \theta^{(t)}) + \ell(\theta^{(t)})$$

$$G_t(\theta) \leq \ell(\theta) \quad \forall \theta, \quad G_t(\theta^{(t)}) = \ell(\theta^{(t)})$$

- **E-step:** $\theta^{(t)}$ 에서 ℓ 에 접하는 하한 G_t 를 만든다 (채운 점)
- **M-step:** G_t 를 최대화 (빈 점) $\rightarrow \ell$ 은 그보다 더 크다 (점선)
- 하한 곡선이 ℓ 보다 뽀족할수록 (결측 정보가 많을수록) 한 스텝이 작아져 수렴이 느려짐

03

Example 1 · Gaussian Mixture Model

1 차원 , 2-class 정규혼합에서 $\pi, \mu_1, \mu_2, \sigma_1, \sigma_2$ 추정

모형과 관측 데이터 log-likelihood

$$Y_i \stackrel{iid}{\sim} \pi N(\mu_1, \sigma_1^2) + (1 - \pi) N(\mu_2, \sigma_2^2), \quad i = 1, \dots, n$$

추정할 모수 $\theta = (\pi, \mu_1, \mu_2, \sigma_1^2, \sigma_2^2)$

관측 데이터 log-likelihood

$$\ell(\theta) = \sum_{i=1}^n \log \left[\pi \phi(y_i; \mu_1, \sigma_1^2) + (1 - \pi) \phi(y_i; \mu_2, \sigma_2^2) \right]$$

왜 직접 풀기 어려운가?

- log 안에 합 (sum) 이 있어 score equation 이 모수끼리 얽힘 → closed form 없음
- likelihood 가 unbounded ($\mu_1 = y_i, \sigma_1 \rightarrow 0$) 이며 국소 최대값이 여러 개

잠재변수 (latent variable) 도입

$$Z_i = \begin{cases} 1 & Y_i \text{ from component 1} \\ 0 & Y_i \text{ from component 2} \end{cases} \quad Z_i \sim \text{Bernoulli}(\pi)$$

z_i 를 알면 두 그룹 각각의 평균 · 분산 → 쉬움

완전 데이터 log-likelihood 와 E-step

완전 데이터 (y_i, z_i) 의 log-likelihood — z_i 에 대해 선형

$$\ell_c(\theta) = \sum_{i=1}^n \left\{ z_i [\log \pi + \log \phi(y_i; \mu_1, \sigma_1^2)] + (1 - z_i) [\log(1 - \pi) + \log \phi(y_i; \mu_2, \sigma_2^2)] \right\}$$

E

E-step: z_i 의 사후확률 (responsibility)

$$\gamma_i^{(t)} = E[Z_i | y_i, \theta^{(t)}] = P(Z_i = 1 | y_i, \theta^{(t)}) = \frac{\pi^{(t)} \phi(y_i; \mu_1^{(t)}, \sigma_1^{2(t)})}{\pi^{(t)} \phi(y_i; \mu_1^{(t)}, \sigma_1^{2(t)}) + (1 - \pi^{(t)}) \phi(y_i; \mu_2^{(t)}, \sigma_2^{2(t)})}$$

ℓ_c 가 z_i 에 대해 선형이므로 z_i 를 $\gamma_i^{(t)}$ 로 바꾸면 Q 함수가 된다:

$$Q(\theta | \theta^{(t)}) = \sum_{i=1}^n \left\{ \gamma_i^{(t)} [\log \pi + \log \phi(y_i; \mu_1, \sigma_1^2)] + (1 - \gamma_i^{(t)}) [\log(1 - \pi) + \log \phi(y_i; \mu_2, \sigma_2^2)] \right\}$$

$\gamma_i^{(t)}$ = "soft label": 관측치 i 가 component 1 에 속할 사후확률

M-step: 가중 (weighted) MLE

M

Q를 각 모수로 미분해 0으로 놓으면 closed form

$$\pi^{(t+1)} = \frac{1}{n} \sum_{i=1}^n \gamma_i^{(t)}$$

$$\mu_1^{(t+1)} = \frac{\sum_i \gamma_i^{(t)} y_i}{\sum_i \gamma_i^{(t)}}$$

$$\mu_2^{(t+1)} = \frac{\sum_i (1 - \gamma_i^{(t)}) y_i}{\sum_i (1 - \gamma_i^{(t)})}$$

$$\sigma_1^{2(t+1)} = \frac{\sum_i \gamma_i^{(t)} (y_i - \mu_1^{(t+1)})^2}{\sum_i \gamma_i^{(t)}}$$

$$\sigma_2^{2(t+1)} = \frac{\sum_i (1 - \gamma_i^{(t)}) (y_i - \mu_2^{(t+1)})^2}{\sum_i (1 - \gamma_i^{(t)})}$$


$\gamma_i \in \{0, 1\}$ 로 강제하면 (hard assignment) k-means와 유사한 알고리즘이 됨. σ^2 갱신에는 새 $\mu^{(t+1)}$ 을 사용.

수치 예제 : $n = 300$ 시뮬레이션 데이터

t	π	μ_1	μ_2	σ_1	σ_2	$\ell(\theta)$
0	0.500	-1.000	1.000	2.000	2.000	-875.14
1	0.271	0.930	3.145	1.880	2.176	-676.08
2	0.273	0.862	3.178	1.749	2.187	-675.12
5	0.280	0.500	3.341	1.424	2.103	-670.54
10	0.305	0.012	3.656	0.957	1.813	-659.84
20	0.332	-0.001	3.811	0.922	1.674	-658.97
50	0.346	0.040	3.872	0.944	1.634	-658.92
89	0.347	0.042	3.875	0.945	1.632	-658.92
참값	0.4	0	4	1	1.5	

초기값 $\theta^{(0)} = (0.5, -1, 1, 2, 2)$. $|\Delta\ell| < 10^{-8}$ 기준으로 89 회 반복 후 수렴.

표본 데이터에 대한 MLE 이므로 참값과 정확히 같지는 않다 (표본 변동).



R 코드

```

em_gmm <- function(y, p = 0.5, mu = c(-1, 1), s = c(2, 2),
  tol = 1e-8, maxit = 500) {
  ll_old <- -Inf
  for (t in 1:maxit) {
    ## E-step: responsibilities gamma_i
    d1 <- p * dnorm(y, mu[1], s[1])
    d2 <- (1 - p) * dnorm(y, mu[2], s[2])
    g <- d1 / (d1 + d2)
    ## M-step: weighted MLEs
    p <- mean(g)
    mu[1] <- sum(g * y) / sum(g)
    mu[2] <- sum((1 - g) * y) / sum(1 - g)
    s[1] <- sqrt(sum(g * (y - mu[1])^2) / sum(g))
    s[2] <- sqrt(sum((1 - g) * (y - mu[2])^2) / sum(1 - g))
    ll <- sum(log(p * dnorm(y, mu[1], s[1]) +
      (1 - p) * dnorm(y, mu[2], s[2])))
    if (abs(ll - ll_old) < tol) break
    ll_old <- ll
  }
  list(pi = p, mu = mu, sigma = s, loglik = ll, iter = t)
}
set.seed(2026)
z <- rbinom(300, 1, 0.4)
y <- ifelse(z == 1, rnorm(300, 0, 1), rnorm(300, 4, 1.5))
str(em_gmm(y))

```

출력 (요약)

 $\hat{\pi} = 0.347$
 $\hat{\mu}_1 = 0.042, \hat{\mu}_2 = 3.875$
 $\hat{\sigma}_1 = 0.945, \hat{\sigma}_2 = 1.632$
 $\ell(\hat{\theta}) = -658.916, \text{ iter} = 89$

실습 포인트

- 초기값을 여러 개 바꿔 보고 $\ell(\hat{\theta})$ 을 비교 (local maxima)
- 매 반복 ℓ 이 감소하지 않는지 확인 (monotonicity)
- label switching: $\mu_1 < \mu_2$ 로 정렬

04

Example 2 · Bivariate Normal with Missing

일부 성분이 결측인 이변량 정규분포에서 μ, Σ 의 MLE

설정 : 결측 패턴과 MAR 가정

$$\mathbf{Y}_i = \begin{pmatrix} Y_{i1} \\ Y_{i2} \end{pmatrix} \stackrel{iid}{\sim} N_2 \left(\begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \begin{pmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{12} & \sigma_{22} \end{pmatrix} \right)$$

- 모수 $\theta = (\mu_1, \mu_2, \sigma_{11}, \sigma_{12}, \sigma_{22})$
- 세 가지 결측 패턴 : ① 둘 다 관측 ② Y_2 만 결측 ③ Y_1 만 결측
- **MAR (Missing At Random):** 결측 여부 R 이 관측된 값에만 의존

$$P(R \mid Y_{\text{obs}}, Y_{\text{mis}}) = P(R \mid Y_{\text{obs}})$$

MAR 이면 결측 메커니즘을 무시 (ignorable) 하고 관측 데이터 likelihood 만 최대화하면 된다 .
반면 complete-case 분석은 MAR 에서 편향될 수 있다 .

데이터 행렬 (예시)

Y ₁	Y ₂	
		① 완전
	?	② Y ₂ 결측
	?	
	?	
	?	
?		③ Y ₁ 결측
?		

충분통계량과 E-step

완전 데이터 충분통계량 (이변량 정규 = 지수족)

$$T_1 = \sum_i y_{i1}, \quad T_2 = \sum_i y_{i2}, \quad T_{11} = \sum_i y_{i1}^2, \quad T_{22} = \sum_i y_{i2}^2, \quad T_{12} = \sum_i y_{i1}y_{i2}$$

E

E-step: Y_2 가 결측인 i 에 대해 (조건부 정규분포 이용)

$$\hat{y}_{i2}^{(t)} = E[Y_{i2} \mid y_{i1}, \theta^{(t)}] = \mu_2^{(t)} + \frac{\sigma_{12}^{(t)}}{\sigma_{11}^{(t)}}(y_{i1} - \mu_1^{(t)})$$

$$E[Y_{i2}^2 \mid y_{i1}, \theta^{(t)}] = (\hat{y}_{i2}^{(t)})^2 + \sigma_{22 \cdot 1}^{(t)}, \quad \sigma_{22 \cdot 1}^{(t)} = \sigma_{22}^{(t)} - \frac{(\sigma_{12}^{(t)})^2}{\sigma_{11}^{(t)}}$$

$$E[Y_{i1}Y_{i2} \mid y_{i1}, \theta^{(t)}] = y_{i1} \hat{y}_{i2}^{(t)}$$

Y_1 이 결측인 경우는 첨자 $1 \leftrightarrow 2$ 를 바꾸어 동일하게 계산 . 완전 관측치는 그대로 사용 .

M-step, 그리고 조건부 분산 항의 역할

M

M-step: 완전 데이터 MLE 공식에 기대 충분통계량을 대입

$$\mu_j^{(t+1)} = \frac{T_j^{(t)}}{n}, \quad \sigma_{jk}^{(t+1)} = \frac{T_{jk}^{(t)}}{n} - \mu_j^{(t+1)} \mu_k^{(t+1)} \quad (j, k = 1, 2)$$

$T^{(t)}$: 관측 데이터와 $\theta^{(t)}$ 가 주어졌을 때 충분통계량의 조건부 기댓값 (E-step 의 결과)

단순 대입 (conditional mean imputation) 은 ?

$\hat{y}_{i2}$ 를 대입한 뒤 표본분산을 구하면 $E[Y^2]$ 대신 $(E[Y])^2$ 를 쓰는 셈
 $\rightarrow \sigma_{22 \cdot 1}$ 만큼 빠져서 분산이 과소추정된다. 평균 추정은 EM 과 같다.

EM 은 " 대입 + 불확실성 보정 "

각 반복에서 회귀 예측값으로 채우고, 예측 불확실성 (조건부 분산) 을 제곱합에 더해 준다. 이를 반복하면 관측 데이터 MLE 로 수렴.

수치 예제 : $n = 200$, MAR 결측

참값 $\mu = (5, 10)$, $\sigma_{11} = 4$, $\sigma_{12} = 3$, $\sigma_{22} = 9$. Y_1 이 클수록 Y_2 가 결측될 확률 $\uparrow$ (MAR). 완전 128 개, Y_2 결측 62 개, Y_1 결측 10 개.

방법	μ_1	μ_2	σ_{11}	σ_{12}	σ_{22}
참값 (모집단)	5	10	4	3	9
결측 전 전체 데이터의 MLE	5.269	10.090	3.603	3.027	9.986
Complete-case (완전 관측치만)	4.559	9.422	3.029	2.655	8.660
조건부 평균 단순 대입	5.248	9.930	3.533	3.154	7.112
EM (35 회 반복)	5.248	9.930	3.662	3.154	9.087

관찰

- Complete-case: Y_1 큰 관측치가 빠져 μ_1, μ_2 모두 아래로 편향
- 단순 대입 : 평균은 EM 과 같지만 σ_{22} 과소추정
- EM: 결측 전 전체 데이터 MLE 에 가장 가까움 (정보 손실만큼의 차이)

R 코드 : `em_bvn()` — 다음 슬라이드

R 코드

```

em_bvn <- function(Y, tol = 1e-8) {          # Y: n x 2, NA = missing
  m1 <- is.na(Y[, 1]); m2 <- is.na(Y[, 2]); n <- nrow(Y)
  mu <- colMeans(Y, na.rm = TRUE); S <- var(Y, use = "complete.obs")
  repeat {
    E <- Y; V <- matrix(0, n, 2)           # V: conditional variances
    ## E-step
    E[m2, 2] <- mu[2] + S[1,2]/S[1,1] * (Y[m2, 1] - mu[1])
    V[m2, 2] <- S[2,2] - S[1,2]^2 / S[1,1]
    E[m1, 1] <- mu[1] + S[1,2]/S[2,2] * (Y[m1, 2] - mu[2])
    V[m1, 1] <- S[1,1] - S[1,2]^2 / S[2,2]
    ## M-step
    mu.new <- colMeans(E)
    S.new <- crossprod(E)/n + diag(colMeans(V)) - tcrossprod(mu.new)
    if (max(abs(c(mu.new - mu, S.new - S))) < tol) break
    mu <- mu.new; S <- S.new
  }
  list(mu = mu.new, Sigma = S.new)
}

```

구현 요령

- E: 결측 칸을 회귀 예측값으로 채움
- V: 조건부 분산을 따로 저장해 제공함 대각에 더함
- 교차곱 $E[Y_1 Y_2]$ 는 $y_1 \cdot \hat{y}_2$ 이므로 `crossprod(E)` 그대로 사용
- 초기값 : complete-case 추정치

05

Example 3 · ABO 혈액형 (Multinomial)

관측되는 것은 phenotype, 모형은 genotype 수준에서 정의

유전 모형 : 대립유전자 A, B, O

- 대립유전자 (allele) 빈도 : $p = P(A)$, $q = P(B)$, $r = P(O)$, $p + q + r = 1$
- **Hardy-Weinberg 평형** : 두 allele 이 독립적으로 결합 → genotype 확률
- A 와 B 는 O 에 대해 우성 → AA 와 AO 는 모두 혈액형 A 로 관측
- 관측 : phenotype 빈도 (n_A, n_B, n_{AB}, n_O) — multinomial
- 완전 데이터 : genotype 빈도 ($n_{AA}, n_{AO}, n_{BB}, n_{BO}, n_{AB}, n_{OO}$)

Phenotype	Genotype	확률 (HWE)	관측 빈도
A	AA	p^2	$n_A = 186$
	AO	$2pr$	
B	BB	q^2	$n_B = 38$
	BO	$2qr$	
AB	AB	$2pq$	$n_{AB} = 13$
O	OO	r^2	$n_O = 284$

데이터 : $n = 521$ (Clarke et al., 1959; Lange, Numerical Analysis for Statisticians의 예제)

n_{AA} 와 n_{AO} (n_{BB} 와 n_{BO}) 의 분할이 "missing" 이다.

관측 vs 완전 데이터 log-likelihood

관측 데이터 (phenotype): log 안에 합 → 직접 최대화 어려움 (제약 $p + q + r = 1$ 도 있음)

$$\ell(p, q, r) = n_A \log(p^2 + 2pr) + n_B \log(q^2 + 2qr) + n_{AB} \log(2pq) + 2n_O \log r$$

완전 데이터 (genotype): allele 개수를 세는 것과 같음 → multinomial MLE 는 단순 비율

$$\ell_c = (2n_{AA} + n_{AO} + n_{AB}) \log p + (2n_{BB} + n_{BO} + n_{AB}) \log q + (2n_{OO} + n_{AO} + n_{BO}) \log r + \text{const}$$

- AA 개인은 A allele 2 개 , AO 개인은 A allele 1 개 → p 의 계수 = A allele 총 개수
- 완전 데이터 MLE: $\hat{\mathbf{p}} = (\mathbf{A \text{ allele 수 }}) / 2\mathbf{n}$, $\hat{q}, \hat{r}$ 도 마찬가지 — "gene counting"
- ℓ_c 는 genotype count 에 대해 선형 → E-step 은 count 의 조건부 기댓값만 계산하면 됨

E-step 과 M-step: Gene counting 알고리즘

E E-step: 주어진 phenotype 안에서 genotype 비율대로 나눈다 (이항분포의 기댓값)

$$n_{AA}^{(t)} = n_A \frac{p^{(t)2}}{p^{(t)2} + 2p^{(t)}r^{(t)}}, \quad n_{AO}^{(t)} = n_A \frac{2p^{(t)}r^{(t)}}{p^{(t)2} + 2p^{(t)}r^{(t)}}$$

$$n_{BB}^{(t)} = n_B \frac{q^{(t)2}}{q^{(t)2} + 2q^{(t)}r^{(t)}}, \quad n_{BO}^{(t)} = n_B \frac{2q^{(t)}r^{(t)}}{q^{(t)2} + 2q^{(t)}r^{(t)}}$$

M M-step: allele counting

$$p^{(t+1)} = \frac{2n_{AA}^{(t)} + n_{AO}^{(t)} + n_{AB}}{2n}$$

$$q^{(t+1)} = \frac{2n_{BB}^{(t)} + n_{BO}^{(t)} + n_{AB}}{2n}$$

$$r^{(t+1)} = \frac{2n_O + n_{AO}^{(t)} + n_{BO}}{2n}$$

```
abo_em <- function(nA = 186, nB = 38, nAB = 13, nO = 284,
                   p = 1/3, q = 1/3, r = 1/3, tol = 1e-10) {
  n <- nA + nB + nAB + nO
  repeat {
    ## E-step: split phenotype counts into genotypes
    nAA <- nA * p^2 / (p^2 + 2*p*r); nAO <- nA - nAA
    nBB <- nB * q^2 / (q^2 + 2*q*r); nBO <- nB - nBB
    ## M-step: gene counting
    new <- c(2*nAA + nAO + nAB,
             2*nBB + nBO + nAB,
             2*nO + nAO + nBO) / (2*n)
    if (max(abs(new - c(p, q, r))) < tol) break
    p <- new[1]; q <- new[2]; r <- new[3]
  }
  c(p = new[1], q = new[2], r = new[3])
}
```

수치 예제 : 빠른 수렴

t	p	q	r	n_AA	n_AO	n_BB	n_BO	$\ell(\theta)$
0	0.33333	0.33333	0.33333	–	–	–	–	-889.654
1	0.25048	0.06110	0.68842	62.00	124.00	12.67	25.33	-516.732
2	0.21845	0.05049	0.73105	28.63	157.37	1.61	36.39	-511.640
3	0.21418	0.05016	0.73566	24.18	161.82	1.27	36.73	-511.572
4	0.21366	0.05015	0.73619	23.64	162.36	1.25	36.75	-511.571
5	0.21360	0.05015	0.73626	23.57	162.43	1.25	36.75	-511.571
12	0.21359	0.05015	0.73626	23.56	162.44	1.25	36.75	-511.571

$t = 0 \rightarrow 1$ 에서 genotype 분할은 $\theta^{(0)} = (1/3, 1/3, 1/3)$ 기준 . 표의 n_AA 등은 해당 행의 θ 를 만들 때 사용된 E-step 값 .

MLE

$$\hat{p} = 0.2136$$

$$\hat{q} = 0.0501$$

$$\hat{r} = 0.7363$$

- 12 회 반복만에 10^{-10} 정밀도로 수렴
- missing 정보 (A, B 내부 분할) 의 비중이 작아 수렴이 빠름
- 제약조건 $p + q + r = 1$ 이 매 반복 자동으로 만족

06

Example 4 · 회귀분석에서 Y 가 결측

Multiple linear regression, X 는 모두 관측 · 일부 y_i 가 결측

설정과 완전 데이터 log-likelihood

$$y_i = \mathbf{x}_i^\top \boldsymbol{\beta} + \varepsilon_i, \quad \varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2), \quad i = 1, \dots, n$$

$$\mathbf{y} = \begin{pmatrix} \mathbf{y}_o \\ \mathbf{y}_m \end{pmatrix} \begin{matrix} \leftarrow m \text{ observed} \\ \leftarrow n - m \text{ missing} \end{matrix} \quad \mathbf{X} = \begin{pmatrix} \mathbf{X}_o \\ \mathbf{X}_m \end{pmatrix} \text{ (fully observed)}$$

완전 데이터 log-likelihood — 충분통계량은 $\mathbf{X}^\top \mathbf{y}$ 와 $\mathbf{y}^\top \mathbf{y}$

$$\ell_c(\boldsymbol{\beta}, \sigma^2) = -\frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \left(\mathbf{y}^\top \mathbf{y} - 2\boldsymbol{\beta}^\top \mathbf{X}^\top \mathbf{y} + \boldsymbol{\beta}^\top \mathbf{X}^\top \mathbf{X} \boldsymbol{\beta} \right)$$

역사적 배경

실험계획법의 분산분석에서 결측 셀이 생기면 균형 (balance) 이 깨져 계산이 어려웠다. Yates (1933) 는 결측값을 " 최소제곱 추정값으로 채우고 다시 적합 " 하는 반복법을 제안했고, Healy & Westmacott (1956) 가 일반화 — 이것이 EM 의 원형 중 하나다.

E-step 과 M-step

E

E-step: 결측 y_i 의 조건부 기댓값 (x 는 관측, y 는 x 만 조건부)

$$\hat{y}_i^{(t)} = E[y_i \mid \theta^{(t)}] = \mathbf{x}_i^\top \boldsymbol{\beta}^{(t)} \quad (i > m)$$

$$E[y_i^2 \mid \theta^{(t)}] = (\mathbf{x}_i^\top \boldsymbol{\beta}^{(t)})^2 + \sigma^{2(t)} \quad (i > m)$$

M

M-step: 채운 데이터로 OLS, σ^2 에는 결측 부분의 분산을 더함

$$\boldsymbol{\beta}^{(t+1)} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \hat{\mathbf{y}}^{(t)}, \quad \hat{\mathbf{y}}^{(t)} = \begin{pmatrix} \mathbf{y}_o \\ \mathbf{X}_m \boldsymbol{\beta}^{(t)} \end{pmatrix}$$

$$\sigma^{2(t+1)} = \frac{1}{n} \left[\sum_{i \leq m} (y_i - \mathbf{x}_i^\top \boldsymbol{\beta}^{(t+1)})^2 + \sum_{i > m} (\mathbf{x}_i^\top \boldsymbol{\beta}^{(t)} - \mathbf{x}_i^\top \boldsymbol{\beta}^{(t+1)})^2 + (n - m) \sigma^{2(t)} \right]$$

수렴점 분석 : EM 은 결국 무엇을 주는가 ?

β 에 대한 고정점 (fixed point) 방정식

$$\beta = (\mathbf{X}^\top \mathbf{X})^{-1} (\mathbf{X}_o^\top \mathbf{y}_o + \mathbf{X}_m^\top \mathbf{X}_m \beta) \iff \mathbf{X}_o^\top \mathbf{X}_o \beta = \mathbf{X}_o^\top \mathbf{y}_o$$


$$\hat{\beta} = (\mathbf{X}_o^\top \mathbf{X}_o)^{-1} \mathbf{X}_o^\top \mathbf{y}_o, \quad \hat{\sigma}^2 = \frac{1}{m} \sum_{i \leq m} (y_i - \mathbf{x}_i^\top \hat{\beta})^2$$

- X 가 모두 관측되고 y 만 결측이면 , 결측 케이스는 β, σ^2 에 대한 정보가 없다 $\rightarrow$ EM 의 극한 = complete-case MLE
- 그럼에도 좋은 교육 예제 : 결측 정보 비율이 수렴 속도를 결정함을 정확히 보여줌

수렴 속도 (선형 수렴)

$$\beta^{(t+1)} - \hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}_m^\top \mathbf{X}_m (\beta^{(t)} - \hat{\beta}), \quad \sigma^{2(t+1)} - \hat{\sigma}^2 \approx \frac{n-m}{n} (\sigma^{2(t)} - \hat{\sigma}^2)$$

$n = 100, m = 70$: 오차의 감소 (log scale)



—●— $\max |\beta^{(t)} - \hat{\beta}|$ —●— $|\sigma^{2(t)} - \hat{\sigma}^2|$

이론적 수렴률 : β 는 0.337 (행렬의 최대 고유값), σ^2 는 $(n-m)/n = 0.30$. 22 회 반복 후 $\ln()$ 결과와 10^{-10} 이내로 일치 .

R 코드

```

em_mlr <- function(X, y, tol = 1e-10) {    # y: NA = missing response
  o <- !is.na(y); n <- length(y); m <- sum(o)
  b <- rep(0, ncol(X)); s2 <- 1
  XtXi <- solve(crossprod(X))
  repeat {
    yh <- ifelse(o, y, X %*% b)           # E-step
    b.new <- drop(XtXi %*% crossprod(X, yh)) # M-step
    s2.new <- (sum((yh - X %*% b.new)^2) + (n - m) * s2) / n
    if (max(abs(c(b.new - b, s2.new - s2))) < tol) break
    b <- b.new; s2 <- s2.new
  }
  list(beta = b.new, sigma2 = s2.new)
}

```

확인

em_mlr(X, y) 의 결과와
 $\text{lm}(y \sim X, \text{subset} = !\text{is.na}(y))$ 의 계수 ,
 RSS/m 이 일치함을 확인해 보자 .

$\text{sum}((y_h - X\beta)^2)$ 에는 관측 잔차
 제곱합과 $X_m(\beta^{(t)} - \beta^{(t+1)})$ 의 제곱합이
 함께 들어 있다 .

X 에도 결측이 있거나 결측 여부가 y 와 관련된 보조변수가 있으면 결측 케이스도 정보를 준다 → 이때 EM(다변량 정규 모형 등) 이 complete-case 보다 효율적 .

07

EM 의 성질과 장단점

Monotonicity, 수렴 , 수렴 속도 , 표준오차

Monotonicity: 매 반복 likelihood 는 감소하지 않는다

$$\ell(\theta^{(t+1)}) \geq \ell(\theta^{(t)})$$

정리 (Dempster, Laird & Rubin, 1977)

EM (또는 GEM) 의 모든 반복에서 관측 데이터 log-likelihood 는 증가하거나 같다 .

증명 : $\ell(\theta) = Q(\theta | \theta^{(t)}) - H(\theta | \theta^{(t)})$ 에서


$$\ell(\theta^{(t+1)}) - \ell(\theta^{(t)}) = \underbrace{[Q(\theta^{(t+1)} | \theta^{(t)}) - Q(\theta^{(t)} | \theta^{(t)})]}_{\geq 0 \text{ (M-step)}} - \underbrace{[H(\theta^{(t+1)} | \theta^{(t)}) - H(\theta^{(t)} | \theta^{(t)})]}_{\leq 0 \text{ (Jensen)}} \geq 0$$

H 부분 : Jensen 부등식 (log 는 concave)

$$\begin{aligned} H(\theta | \theta^{(t)}) - H(\theta^{(t)} | \theta^{(t)}) &= E \left[\log \frac{k(Z | y; \theta)}{k(Z | y; \theta^{(t)})} \middle| y, \theta^{(t)} \right] \leq \log E \left[\frac{k(Z | y; \theta)}{k(Z | y; \theta^{(t)})} \middle| y, \theta^{(t)} \right] = \log 1 = 0 \\ &= -\text{KL}(k(\cdot | y; \theta^{(t)}) \| k(\cdot | y; \theta)) \leq 0 \end{aligned}$$

즉 $H(\cdot | \theta^{(t)})$ 는 $\theta = \theta^{(t)}$ 에서 최대 (Gibbs 부등식). Q 만 증가시키면 ℓ 도 증가.

Example 1: $\ell(\theta^{(t)})$ 의 증가



수렴과 수렴 속도

수렴 (Wu, 1983)

- ℓ 이 위로 유계이면 $\{\ell(\theta^{(t)})\}$ 는 단조 수렴
- 정착 조건 하에서 $\{\theta^{(t)}\}$ 의 극한점은 ℓ 의 stationary point
- 전역 최대 보장 없음 : 국소 최대 또는 saddle point 가능 → 여러 초기값 사용

Missing information principle

$$I_{\text{obs}}(\theta) = I_c(\theta) - I_m(\theta)$$

$$I_c = E \left[- \frac{\partial^2 \ell_c}{\partial \theta \partial \theta^\top} \middle| y \right], \quad I_m = E \left[- \frac{\partial^2 \log k(Z | y; \theta)}{\partial \theta \partial \theta^\top} \middle| y \right]$$

(Orchard & Woodbury, 1972): 관측 정보 = 완전 정보 - 결측 정보

수렴 속도 : 선형 (linear) 수렴

$$\theta^{(t+1)} - \hat{\theta} \approx J(\hat{\theta}) (\theta^{(t)} - \hat{\theta}), \quad J(\hat{\theta}) = I_c(\hat{\theta})^{-1} I_m(\hat{\theta})$$

- J 의 최대 고유값 = **결측 정보의 비율 (fraction of missing information)** — 클수록 느림
- 예 : ABO (결측 비율 작음) 12 회 vs GMM (component 가 겹침) 89 회, MLR 은 이론치 $(n-m)/n$ 그대로

표준오차 : EM 은 Hessian 을 주지 않는다

EM 의 출력은 $\hat{\theta}$ 뿐 — 관측 정보행렬 $I_{\text{obs}}(\hat{\theta})$ 은 따로 계산해야 한다

Louis (1982)

완전 데이터 기준 양으로 관측 정보를 계산

$$I_{\text{obs}}(\hat{\theta}) = E \left[- \frac{\partial^2 \ell_c}{\partial \theta \partial \theta^\top} \mid y \right] - \text{Var} \left[\frac{\partial \ell_c}{\partial \theta} \mid y \right] \Big|_{\theta=\hat{\theta}}$$

SEM (Meng & Rubin, 1991)

EM 반복으로 J 를 수치적으로 추정해 이용

$$I_{\text{obs}}^{-1} = (I - J)^{-1} I_c^{-1}$$

Score 수치미분

ℓ 의 gradient 는 Q 의 gradient 와 같음 $\rightarrow$
수치미분으로 Hessian

$$\nabla \ell(\theta^{(t)}) = \nabla_{\theta} Q(\theta \mid \theta^{(t)}) \Big|_{\theta=\theta^{(t)}}$$

Bootstrap: 데이터를 재표본하여 EM 을 반복 적용 — 가장 간단하지만 계산량이 큼 . Laplace/profile likelihood 도 대안 .

EM 의 장단점

장점

- **안정성** : 매 반복 ℓ 단조 증가 (monotonicity), 발산하지 않음
- **단순함** : E, M 단계가 closed form 인 경우가 많고 구현이 쉬움
- **제약조건 자동 만족** : 확률의 합 = 1, 분산 > 0 , $\Sigma > 0$
- **튜닝 불필요** : step size, line search 없음
- 반복당 계산량이 작고 메모리 효율적
- **통계적 해석이 명확** : γ_i , 대입값 등 부산물 활용

단점

- **느린 수렴** : 선형 수렴, 결측 정보가 많으면 매우 느림
- **국소 최대 / saddle point** : 초기값에 민감
- **표준오차 미제공** : Louis, SEM, bootstrap 필요
- **E-step 적분이 intractable** 할 수 있음 $\rightarrow$ MCEM
- **M-step closed form 이 없을 수 있음** $\rightarrow$ 수치 최적화 / ECM
- 느린 수렴 때문에 수렴 판정이 조기 종료될 위험

가속 · 변형

Aitken 가속

SQUAREM

PX-EM

ECM / ECME

EM-Newton hybrid

Online / Stochastic EM

정리

E 완전 데이터 log-likelihood 의 조건부 기댓값 $Q(\theta \mid \theta^{(t)})$ — 지수족이면 기대 충분통계량

M Q 를 최대화 — 완전 데이터 MLE 공식에 기대 충분통계량을 대입

↑ $\ell(\theta^{(t)})$ 는 단조 증가 · 선형 수렴 · 속도는 결측 정보 비율이 결정

References

Dempster, Laird & Rubin (1977). Maximum likelihood from incomplete data via the EM algorithm. JRSS-B, 39, 1–38.

Wu (1983). On the convergence properties of the EM algorithm. Ann. Statist., 11, 95–103.

Louis (1982), JRSS-B · Meng & Rubin (1991), JASA · Little & Rubin (2019). Statistical Analysis with Missing Data, 3rd ed.

McLachlan & Krishnan (2008). The EM Algorithm and Extensions, 2nd ed. · Givens & Hoeting (2013). Computational Statistics, Ch. 4.