

EM 알고리즘의 확장

E-step · M-step 을 수치적으로 풀어야 할 때

Monte Carlo EM (MCEM) · Newton / EM gradient · GEM · ECM



$\approx$



EM Algorithm 강의의 후속 슬라이드

표준 EM 이 막히는 두 지점

EM 의 두 단계 중 어느 하나라도 closed form 이 없으면 그 단계를 수치적으로 근사해야 한다 .



E-step 이 어려울 때

$Q(\theta | \theta^{(t)})$ 의 적분이 intractable

- Monte Carlo EM (MCEM): 조건부 분포에서 표본을 뽑아 Q 를 평균으로 근사
- Stochastic EM, SAEM, importance sampling
- 예 : GLMM, 중도절단 , 비선형 잠재변수 모형



M-step 이 어려울 때

$\operatorname{argmax} Q(\theta | \theta^{(t)})$ 의 closed form 이 없음

- 내부 반복 : Newton–Raphson, BFGS (optim)
- EM gradient (Newton 한 스텝), GEM
- ECM: 모수 블록별 조건부 최대화
- 예 : t 분포의 자유도 ν , GLMM 의 β



Monte Carlo EM (MCEM)

E-step 의 조건부 기댓값을 Monte Carlo 평균으로 대체

E-step 이 intractable 한 예 : GLMM

Random intercept logistic model (i = cluster, j = 관측)

$$y_{ij} \mid b_i \sim \text{Bernoulli}(p_{ij}), \quad \text{logit}(p_{ij}) = \mathbf{x}_{ij}^\top \boldsymbol{\beta} + b_i, \quad b_i \stackrel{iid}{\sim} N(0, \sigma_b^2)$$

잠재변수 = random effect b_i . E-step 에서 필요한 Q 함수 :

$$Q(\theta \mid \theta^{(t)}) = \sum_i \int \left[\sum_j \log f(y_{ij} \mid b_i; \boldsymbol{\beta}) + \log \phi(b_i; 0, \sigma_b^2) \right] k(b_i \mid \mathbf{y}_i; \theta^{(t)}) db_i$$

문제 : 조건부 분포가 표준분포가 아님

$$k(b_i \mid \mathbf{y}_i; \theta) \propto \prod_j f(y_{ij} \mid b_i; \boldsymbol{\beta}) \phi(b_i; 0, \sigma_b^2)$$

Bernoulli $\times$ Normal 은 conjugate 가 아니므로 정규화 상수와 기댓값이 closed form 으로 계산되지 않음 .

비슷한 상황

- Poisson / binomial GLMM, crossed random effects
- 다변량 중도절단 (다차원 truncated normal)
- 공간 · 시계열 잠재과정 , 비선형 측정오차 모형

MCEM 알고리즘 (Wei & Tanner, 1990)

Simulation

1

현재 $\theta^{(t)}$ 에서 결측 데이터의 조건부 분포로부터 m_t 개 표본 추출

$$z^{(1)}, \dots, z^{(m_t)} \sim k(z \mid y; \theta^{(t)})$$

MC E-step

2

Q 를 Monte Carlo 평균으로 근사

$$\hat{Q}_{m_t}(\theta \mid \theta^{(t)}) = \frac{1}{m_t} \sum_{j=1}^{m_t} \log f_c(y, z^{(j)}; \theta)$$

M-step

3

근사된 $\hat{Q}$ 를 최대화 (완전 데이터 MLE 와 같은 형태)

$$\theta^{(t+1)} = \arg \max_{\theta} \hat{Q}_{m_t}(\theta \mid \theta^{(t)})$$

$$\hat{Q}_{m_t}(\theta \mid \theta^{(t)}) \longrightarrow Q(\theta \mid \theta^{(t)}) \quad (m_t \rightarrow \infty)$$

→ m_t 가 크면 원래 EM 과 같아짐 (대수의 법칙)

표본 추출 방법

직접 추출 / 역변환

Rejection sampling

Importance sampling

MCMC (Gibbs, Metropolis-Hastings)

구현 시 고려사항

Monte Carlo 표본 크기 m_t

- 초기에는 작게 (θ 가 멀리 있을 때 정밀도 불필요)
- 반복이 진행될수록 증가: $m_t = m_0 \cdot c^t$ 등
- m_t 고정 $\rightarrow \theta^{(t)}$ 가 MLE 주변에서 계속 요동 (MC 오차)

Monotonicity 와 수렴 판정

- MC 오차 때문에 ℓ 단조 증가가 보장되지 않음
- $|\Delta\theta| < \varepsilon$ 가 우연히 만족될 수 있음 $\rightarrow$ 여러 번 연속 만족 시 종료
- Booth & Hobert (1999): ascent 기반 m_t 자동 조정
- 마지막 몇 반복의 $\theta^{(t)}$ 평균을 최종 추정치로

Importance sampling E-step

$$\hat{Q} = \frac{\sum_j w_j \log f_c(y, z^{(j)}; \theta)}{\sum_j w_j}, \quad w_j = \frac{\tilde{k}(z^{(j)} | y; \theta^{(t)})}{g(z^{(j)})}, \quad z^{(j)} \sim g$$

$\tilde{k}$ 는 정규화 상수를 모르는 조건부 밀도. 제안분포 g 에서 한 번 뽑은 표본을 여러 반복에서 가중치만 바꿔 재사용 가능.

Stochastic EM · SAEM

SEM: $m_t = 1$ (한 개만 대입) $\rightarrow$ 정상 분포를 갖는 Markov chain. SAEM (Delyon, Lavielle & Moulines, 1999): 확률적 근사로 Q 를 누적 평균

$$\tilde{Q}_t(\theta) = \tilde{Q}_{t-1}(\theta) + \gamma_t [\hat{Q}_{m_t}(\theta | \theta^{(t)}) - \tilde{Q}_{t-1}(\theta)], \quad \sum_t \gamma_t = \infty, \sum_t \gamma_t^2 < \infty$$

예제 : 오른쪽 중도절단 (right-censored) 정규 데이터

$$X_i \stackrel{iid}{\sim} N(\mu, \sigma^2), \quad \text{observe } y_i = \min(X_i, c), \quad \delta_i = I(X_i > c)$$

중도절단된 관측치의 실제 값 $X_i (> c)$ 가 결측 . 충분통계량 $\sum x_i, \sum x_i^2$ 의 조건부 기댓값이 필요 .

정확한 E-step (truncated normal 적률)

$$E[X \mid X > c] = \mu + \sigma \lambda(a), \quad E[X^2 \mid X > c] = \mu^2 + \sigma^2 + \sigma(c + \mu)\lambda(a)$$

$$a = \frac{c - \mu}{\sigma}, \quad \lambda(a) = \frac{\phi(a)}{1 - \Phi(a)} \quad (\text{inverse Mills ratio})$$

MC E-step (역변환 추출)

$$x_i^{(j)} = \mu^{(t)} + \sigma^{(t)} \Phi^{-1}(U_{ij}), \quad U_{ij} \sim \text{Unif}(\Phi(a^{(t)}), 1), \quad j = 1, \dots, m_t$$

각 절단 관측치마다 m_t 개를 뽑아 $\bar{x}_i, \overline{x_i^2}$ 평균을 계산

M


M-step (두 방법 공통 , closed form)

$$\mu^{(t+1)} = \frac{1}{n} \left[\sum_{\delta_i=0} y_i + \sum_{\delta_i=1} \bar{x}_i^{(t)} \right], \quad \sigma^{2(t+1)} = \frac{1}{n} \left[\sum_{\delta_i=0} y_i^2 + \sum_{\delta_i=1} \overline{x_i^2}^{(t)} \right] - (\mu^{(t+1)})^2$$

정확한 E-step 이 있으므로 MCEM 과 EM 을 직접 비교할 수 있는 교육용 예제

결과 : EM vs MCEM ($n = 100, c = 1.5$)

$\mu^{(t)}$ 의 경로 (초기값 $\mu^{(0)} = 0, \sigma^{(0)} = 2$; $t \geq 1$ 표시)



— EM (정확한 E-step) — MCEM, $m = 10$ 고정 — MCEM, $m_t = [10 \cdot 1.25^t]$

방법	$\hat{\mu}$	$\hat{\sigma}$
중도절단 전 원자료 (참고)	1.011	0.852
절단값 c 를 그대로 사용 (naive)	0.851	0.661
EM (40 회)	1.036	0.905
MCEM, $m = 10$	1.058	0.942
MCEM, m_t 증가	1.036	0.905

- $n = 100$ 중 32 개가 $c = 1.5$ 에서 절단 (참값 $\mu = 1, \sigma = 1$)
- naive 방법은 μ, σ 모두 심하게 과소추정
- m 고정 MCEM 은 EM 경로 주변에서 계속 요동
- m_t 를 늘리면 MC 오차가 줄어 EM 의 MLE 로 수렴

R 코드 : 중도절단 정규 데이터의 MCEM

```

mcem_cens <- function(x, cens, c, mu = 0, s = 2,
                      T = 40, m0 = 10, inc = 1.25) {
  n <- length(x); k <- sum(cens); path <- mu
  for (t in 1:T) {
    m <- ceiling(m0 * inc^t) # MC sample size grows
    ## MC E-step: Z | Z > c by inverse-cdf sampling
    a <- pnorm(c, mu, s)
    Z <- matrix(qnorm(runif(k * m, a, 1), mu, s), k, m)
    S1 <- sum(x[!cens]) + sum(rowMeans(Z))
    S2 <- sum(x[!cens]^2) + sum(rowMeans(Z^2))
    ## M-step (closed form)
    mu <- S1 / n; s <- sqrt(S2 / n - mu^2); path <- c(path, mu)
  }
  list(mu = mu, sigma = s, path = path)
}
set.seed(3); x0 <- rnorm(100, 1, 1); cens <- x0 > 1.5; x <- pmin(x0, 1.5)
r <- mcem_cens(x, cens, 1.5); print(c(r$mu, r$sigma))

```

포인트

- `runif(k·m, a, 1)` 을 `qnorm` 에 넣으면 $X | X > c$ 의 정확한 표본
- `rowMeans` 로 관측치별 MC 평균
→ 충분통계량의 근사
- M-step 은 원래 EM 과 동일
- `m0, inc` 를 바꿔 수렴 경로를 비교해 보기

GLMM 처럼 직접 추출이 어려우면 이 부분을 Metropolis-Hastings 나 importance sampling 으로 교체한다 .

B

Numerical M-step

$\operatorname{argmax} Q(\theta \mid \theta^{(t)})$ 가 closed form 이 아닐 때

M-step 에 closed form 이 없는 경우

E-step 은 쉽지만 , $Q(\theta | \theta^{(t)})$ 의 score equation 이 비선형이라 풀리지 않는 경우가 흔하다 .

t 분포의 자유도 ν

Q 에 $\log \Gamma(\nu/2)$, digamma 가 등장 $\rightarrow$ 1 차원 방정식을 수치적으로 풀기 (뒤의 예제)

GLMM 의 고정효과 β

MC 표본으로 채운 데이터에서 가중 logistic regression $\rightarrow$ IRLS/Newton

Mixture of experts

혼합비율이 공변량에 의존 (multinomial logit) $\rightarrow$ 반복 최적화

Gamma · Weibull 혼합

shape 모수의 MLE 가 closed form 이 아님

Random effects 분산 성분

모수화에 따라 제약된 비선형 최적화

Latent class / IRT 모형

문항 모수 추정이 logistic 형태

수치적 M-step 전략

Full inner optimization

1

M-step 안에서 Newton-Raphson / BFGS (optim) 를 수렴할 때까지 반복 . 정확하지만 반복당 비용이 큼 .

$$\theta \leftarrow \theta - [\nabla_{\theta}^2 Q(\theta \mid \theta^{(t)})]^{-1} \nabla_{\theta} Q(\theta \mid \theta^{(t)}) \quad (\text{inner loop until convergence})$$

EM gradient (Lange, 1995)

2

Newton 한 스텝만 수행 . $\theta^{(t)}$ 에서 $\nabla Q = \nabla \ell$ (score) 이므로 score 와 Q 의 Hessian 만 있으면 됨 .

$$\theta^{(t+1)} = \theta^{(t)} - [\nabla_{\theta}^2 Q(\theta \mid \theta^{(t)})|_{\theta=\theta^{(t)}}]^{-1} \nabla \ell(\theta^{(t)})$$

ECM (Meng & Rubin, 1993)

3

모수를 블록으로 나눠 조건부 최대화 (CM-step) 를 차례로 수행 . $\theta_s^{(t+1)} = \arg \max_{\theta_s} Q(\theta_1^{(t+1)}, \dots, \theta_{s-1}^{(t+1)}, \theta_s, \theta_{s+1}^{(t)}, \dots, \theta_S^{(t)} \mid \theta^{(t)})$, $s = 1, \dots, S$
각 CM-step 은 쉬운 경우가 많음 .

GEM 원리 : $Q(\theta^{(t+1)} \mid \theta^{(t)}) \geq Q(\theta^{(t)} \mid \theta^{(t)})$ 만 만족하면 monotonicity 유지 $\rightarrow$ 2, 3 도 (step-halving 등으로 증가를 보장하면) 단조 증가 . ECME (Liu & Rubin, 1994): 일부 블록은 ℓ 자체를 최대화해 가속 .

예제 : t 분포 (μ, σ^2, ν) — ECM

$$Y_i \mid W_i = w \sim N(\mu, \sigma^2/w), \quad W_i \sim \text{Gamma}\left(\frac{\nu}{2}, \frac{\nu}{2}\right) \implies Y_i \sim t_\nu(\mu, \sigma^2)$$

E

E-step: 잠재 가중치 W_i 의 조건부 기댓값 ($W \mid y \sim \text{Gamma}$)

$$w_i^{(t)} = E[W_i \mid y_i, \theta^{(t)}] = \frac{\nu^{(t)} + 1}{\nu^{(t)} + d_i^{(t)}}, \quad d_i^{(t)} = \frac{(y_i - \mu^{(t)})^2}{\sigma^{2(t)}} \quad \ell_i^{(t)} = E[\log W_i \mid y_i, \theta^{(t)}] = \psi\left(\frac{\nu^{(t)} + 1}{2}\right) - \log \frac{\nu^{(t)} + d_i^{(t)}}{2}$$

M

CM-step 1: ν 고정 $\rightarrow$ 가중 평균 · 분산 (closed form)

$$\mu^{(t+1)} = \frac{\sum_i w_i^{(t)} y_i}{\sum_i w_i^{(t)}}, \quad \sigma^{2(t+1)} = \frac{1}{n} \sum_i w_i^{(t)} (y_i - \mu^{(t+1)})^2$$

M

CM-step 2: ν 에 대한 Q 를 최대화 — closed form 없음 $\rightarrow$ uniroot

$$-\psi\left(\frac{\nu}{2}\right) + \log \frac{\nu}{2} + 1 + \frac{1}{n} \sum_{i=1}^n (\ell_i^{(t)} - w_i^{(t)}) = 0$$

v 에 대한 목적함수와 수치 결과

v 가 포함된 Q 의 부분 (Gamma(v/2, v/2) 밀도의 기댓값)


$$Q(\nu) = n \left[\frac{\nu}{2} \log \frac{\nu}{2} - \log \Gamma\left(\frac{\nu}{2}\right) \right] + \frac{\nu}{2} \sum_{i=1}^n (\ell_i^{(t)} - w_i^{(t)}) + \text{const}$$

$\psi = \text{digamma}$. 이를 v 로 미분해 0 으로 놓은 식이 CM-step 2 (단조함수라 근이 하나 , uniroot 로 안정적).

	μ	σ	ν	ℓ
초기값 (t = 0)	1.842	1.881	10.00	-607.973
ECM (t = 125)	1.827	1.402	4.413	-598.306
optim() 직접 최대화	1.827	1.402	4.413	-598.306
참값	2	1.5	4	

$n = 300, y = 2 + 1.5 \cdot t_4$. ECM 의 결과가 전체 likelihood 를 직접 최대화한 결과와 일치 .

$\nu^{(t)}$ 의 수렴 (ECM)



R 코드 : t 분포의 ECM

```
ecm_t <- function(y, mu = median(y), s2 = var(y), nu = 10,
                 tol = 1e-9, maxit = 1000) {
  ll <- function(mu, s2, nu)
    sum(dn((y - mu)/sqrt(s2), nu, log = TRUE) - 0.5*log(s2))
  old <- ll(mu, s2, nu)
  for (t in 1:maxit) {
    d2 <- (y - mu)^2 / s2                # E-step
    w <- (nu + 1) / (nu + d2)
    El <- digamma((nu + 1)/2) - log((nu + d2)/2)
    mu <- sum(w * y) / sum(w)            # CM-step 1
    s2 <- mean(w * (y - mu)^2)
    f <- function(v) -digamma(v/2) + log(v/2) + 1 + mean(El - w)
    nu <- uniroot(f, c(0.05, 1000))$root # CM-step 2
    new <- ll(mu, s2, nu)
    if (abs(new - old) < tol) break
    old <- new
  }
  c(mu = mu, sigma = sqrt(s2), nu = nu, iter = t)
}
set.seed(5); y <- 2 + 1.5 * rt(300, df = 4); print(ecm_t(y))
```

포인트

- E-step 결과 (w, El) 는 한 번 계산해 두 CM-step 에서 공유
- CM-step 2 는 1 차원 근 찾기 → `uniroot` (또는 `optimize`)
- v 가 매우 크면 정규분포에 가까워져 likelihood 가 평평 → 탐색 구간의 상한 필요
- 느린 수렴 (125 회): v 방향의 결측 정보가 큼

정리 : 어떤 방법을 언제 쓰는가

방법	상황	단조성	반복당 비용	비고
표준 EM	E, M 모두 closed form	보장	낮음	가장 단순 , 느릴 수 있음
MCEM	E-step 적분 intractable	MC 오차 내에서 근사적	높음 (m_t 증가)	m_t 스케줄 , 수렴 판정 주의
SAEM / Stochastic EM	E-step 적분 intractable	확률적 수렴	낮음 ~ 중간	step size γ_t 조건 필요
Inner Newton / optim	M-step closed form 없음	보장 (정확히 최대화 시)	중간 ~ 높음	EM 반복 $\times$ 내부 반복
EM gradient	M-step closed form 없음	Q 증가 시 보장 (GEM)	낮음	국소적으로 EM 과 같은 수렴률
ECM / ECME	블록별로는 쉬움	보장 (GEM)	낮음	실무에서 가장 흔한 선택

References

Wei & Tanner (1990), JASA 85, 699–704 · Booth & Hobert (1999), JRSS-B 61, 265–285 · Delyon, Lavielle & Moulines (1999), Ann. Statist. 27, 94–128
 Lange (1995), JRSS-B 57, 425–437 · Meng & Rubin (1993), Biometrika 80, 267–278 · Liu & Rubin (1994), Biometrika 81, 633–648
 McLachlan & Krishnan (2008). The EM Algorithm and Extensions, 2nd ed. · Givens & Hoeting (2013). Computational Statistics, Ch. 4.