

Monte Carlo Simulation

몬테카를로 방법과 난수 생성 (random variate generation)

대수의 법칙 · Inverse CDF · Rejection Sampling · Sampling Importance Resampling



교재 : Givens & Hoeting, Computational Statistics, 2nd ed. (Wiley, 2013)

목차

01

Monte Carlo 방법의 기본 개념

기댓값 · 적분을 표본평균으로, π 추정 예제

02

대수의 법칙과 Monte Carlo 오차

SLLN, CLT, 표준오차, 수렴이 실패하는 경우

03

Inverse CDF 방법

정리와 증명, 연속 · 이산 · 절단 분포

04

Rejection Sampling

Envelope, 수락률, Beta 와 베이지 사후분포 예제

05

Sampling Importance Resampling

가중치와 재표본, slash 분포, 사후분포 예제

+

정리

세 방법 비교와 참고문헌

01

Monte Carlo 방법의 기본 개념

구하기 어려운 기댓값 (적분) 을 난수 표본의 평균으로 근사한다

Monte Carlo 방법이란 ?

- 관심 있는 양을 기댓값 (적분) 으로 표현하고 , 그 기댓값을 난수 표본의 평균으로 근사
- 이름의 유래 : Los Alamos 의 Ulam, von Neumann, Metropolis — 모나코의 카지노 "Monte Carlo" (Metropolis & Ulam, 1949)
- 활용
 - 고차원 적분 , 확률 계산 (p-value, 검정력)
 - 통계량의 표본분포 , bootstrap
 - 베이즈 사후분포의 요약 (평균 , 신용구간)
- 핵심 전제 : **f 에서 표본을 뽑을 수 있어야 한다** → Part 3-5 의 주제 (난수 생성)

목표 : 기댓값 (적분)

$$\mu = E_f[h(X)] = \int h(x) f(x) dx$$

Monte Carlo 추정량

$$\hat{\mu}_{MC} = \frac{1}{n} \sum_{i=1}^n h(X_i), \quad X_1, \dots, X_n \stackrel{iid}{\sim} f$$


예시 : 무엇이든 기댓값으로

확률 $P(X \in A) = E[I(X \in A)]$

적분 $\int g(x)dx = E[g(X)/f(X)]$

분위수 , 분산 , 사후평균 ...

예제 : 원주율 π 의 Monte Carlo 추정



단위정사각형에 균등하게 점을 뿌리고, 사분원 안에 들어간 비율을 센다

$$\pi = 4 P(U_1^2 + U_2^2 \leq 1) = 4 E[I(U_1^2 + U_2^2 \leq 1)], \quad U_1, U_2 \stackrel{iid}{\sim} \text{Unif}(0, 1)$$

n	$\hat{\pi}$	SE	95% CI
10,000	3.1312	0.0165	(3.099, 3.164)

- $h(U_1, U_2) = I(U_1^2 + U_2^2 \leq 1)$ 는 Bernoulli($\pi/4$) $\rightarrow$ **SE = $4\sqrt{p(1-p)/n}$**
- 참값 $\pi = 3.14159$ 는 95% 신뢰구간 안에 있음
- 소수 둘째 자리 정확도 $\rightarrow n \approx 10^4$, 셋째 자리 $\rightarrow n \approx 10^6$ (오차 $\propto 1/\sqrt{n}$)

적분을 기댓값으로 : Monte Carlo 적분

$$\int_a^b g(x) dx = (b - a) E[g(U)], \quad U \sim \text{Unif}(a, b)$$

예제 : 원시함수가 초등함수로 표현되지 않는 적분

$$\mu = \int_0^1 e^{x^2} dx = E[e^{U^2}] \approx 1.462652$$

n	$\hat{\mu}$	SE	95% CI	μ 포함 ?
10	1.55809	0.17520	(1.2147, 1.9015)	✓
100	1.46598	0.05092	(1.3662, 1.5658)	✓
1,000	1.46996	0.01543	(1.4397, 1.5002)	✓
10,000	1.46968	0.00480	(1.4603, 1.4791)	✓
100,000	1.46541	0.00151	(1.4625, 1.4684)	✓

관찰

- n 이 100 배 커질 때마다 SE 는 약 1/10
- $\sigma = \text{sd}(h) \approx 0.476$ 이므로 $\text{SE} \approx 0.476/\sqrt{n}$
- 참값 : integrate() 로 1.462652
- 1 차원에서는 수치적분이 훨씬 효율적 — MC 의 장점은 고차원에서 드러남

02


대수의 법칙과 Monte Carlo 오차

MC 추정이 왜 맞는지 (LLN), 얼마나 맞는지 (CLT)

강대수의 법칙 (Strong Law of Large Numbers)

$$\hat{\mu}_n \xrightarrow{a.s.} \mu \quad (n \rightarrow \infty), \quad \text{if } E_f|h(X)| < \infty$$

- $X_1, X_2, \dots$ iid $\sim f$ 이고 $E|h(X)| < \infty$ 이면 표본평균은 거의 확실하게 (a.s.) μ 로 수렴
- MC 추정의 **일치성 (consistency)** 을 보장하는 이론적 근거
- 그림 : 서로 다른 seed 로 만든 5 개의 running mean 경로
 - 초기에는 경로마다 크게 다르지만 , 모두 μ 로 모임
 - 회색 띠 $\mu \pm 2\sigma/\sqrt{n}$: 흔들림의 폭이 $1/\sqrt{n}$ 으로 줄어듦 (CLT)
- LLN 은 " 언젠가 맞는다 " 만 말함 $\rightarrow$ 얼마나 정확한지는 CLT 로



CLT 와 Monte Carlo 표준오차

분산과 중심극한정리

$$\text{Var}(\hat{\mu}_n) = \frac{\sigma^2}{n}, \quad \sigma^2 = \text{Var}_f[h(X)]$$

$$\sqrt{n}(\hat{\mu}_n - \mu) \xrightarrow{d} N(0, \sigma^2)$$

추정된 표준오차와 신뢰구간

$$\widehat{SE}(\hat{\mu}_n) = \frac{\hat{\sigma}}{\sqrt{n}}, \quad \hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (h(X_i) - \hat{\mu}_n)^2$$

$$\hat{\mu}_n \pm 1.96 \frac{\hat{\sigma}}{\sqrt{n}}$$


MC 오차의 수렴 속도

MC error = $O_p(n^{-1/2})$ (independent of dimension d)

grid quadrature error = $O(n^{-k/d})$ (k: 격자 적분법의 차수, d: 차원)

- 정확도를 10 배 높이려면 n 을 **100 배** 늘려야 함 → 느리지만
- 차원이 커져도 속도가 그대로 → **고차원 적분에서 MC 가 유리**
- 같은 n 에서 σ 를 줄이는 기법 : 분산감소 (importance sampling, control variates, antithetic) — **교재 6.4 절**

LLN 이 성립하지 않는 경우 : Cauchy 분포



MC 를 쓰기 전에 $h(X)$ 의 적률이 존재하는지 확인하자 .

$E|X| = \infty$ 이면

Cauchy 분포는 평균이 존재하지 않는다 .
표본평균 $\bar{X}_n$ 자체가 다시 $\text{Cauchy}(0,1)$ 을
따르므로 n 을 늘려도 수렴하지 않고 , 가끔 나오는
극단값이 경로를 크게 흔든다 .

$\text{Var} = \infty$ 이지만 $E|X| < \infty$ 이면

LLN 은 성립하지만 CLT 가 깨짐 $\rightarrow \hat{\sigma}/\sqrt{n}$
표준오차와 신뢰구간을 믿을 수 없음 . 예 : t_2
분포의 평균 , 꼬리가 무거운 가중치의
importance sampling.

R 코드 : π 추정과 Monte Carlo 적분

```
## pi = 4 * P(U1^2 + U2^2 <= 1), (U1, U2) ~ Unif(0,1)^2
set.seed(1)
n <- 10000
x <- runif(n); y <- runif(n)
inside <- (x^2 + y^2 <= 1)           # indicator h(X)
pi.hat <- 4 * mean(inside)
se <- 4 * sd(inside) / sqrt(n)      # Monte Carlo standard error
c(pi.hat = pi.hat, se = se)
```

출력

$\hat{\pi} = 3.1312$, SE = 0.0165

$\hat{\mu} = 1.46541$, SE = 0.00151 ($n = 10^5$)

95% CI = (1.4625, 1.4684)

integrate(): 1.462652

```
## mu = int_0^1 exp(x^2) dx = E[exp(U^2)], U ~ Unif(0,1)
set.seed(2)
n <- 100000
h <- exp(runif(n)^2)                # h(U_i)
mu.hat <- mean(h)
se <- sd(h) / sqrt(n)
c(mu.hat = mu.hat, se = se,
  lower = mu.hat - 1.96 * se, upper = mu.hat + 1.96 * se)
integrate(function(x) exp(x^2), 0, 1)$value # 1.462652 (check)

## running mean: law of large numbers
run <- cumsum(h) / seq_along(h)
plot(run, type = "l", log = "x", xlab = "n", ylab = "running mean")
abline(h = 1.462652, lty = 2)

## LLN fails without E|X| < Inf : Cauchy
z <- rcauchy(n)
plot(cumsum(z) / seq_along(z), type = "l", log = "x")
```

03

Inverse CDF 방법

Uniform 난수 하나를 분포함수의 역함수에 넣는다

Inverse CDF 정리 (Probability integral transform)

$$U \sim \text{Unif}(0, 1) \implies X = F^{-1}(U) \sim F$$

증명 (F 가 연속 · 순증가일 때)


$$P(F^{-1}(U) \leq x) = P(U \leq F(x)) = F(x)$$

F 가 순증가가 아니거나 이산형이면 일반화된 역함수를 쓴다 (정리는 그대로 성립):

$$F^{-}(u) = \inf\{x : F(x) \geq u\}, \quad 0 < u < 1$$

역방향도 성립

$$F(X) \sim \text{Unif}(0, 1) \quad (\text{probability integral transform, } F \text{ continuous})$$




y 축의 u 를 곡선에 대고 x 축으로 내린다 : 기울기가 큰 (밀도가 높은) 곳에 x 가 많이 떨어진다

예제 1: 역함수가 닫힌 형태인 연속분포


$$F(x) = 1 - e^{-\lambda x} \Rightarrow X = -\frac{1}{\lambda} \log(1 - U) \stackrel{d}{=} -\frac{1}{\lambda} \log U$$

분포	$F^{-1}(u)$	R 코드
Exponential(λ)	$-\log(1-u)/\lambda$	<code>-log(runif(n))/lambda</code>
Cauchy(0,1)	$\tan(\pi(u - 1/2))$	<code>tan(pi*(runif(n)-0.5))</code>
Logistic(0,1)	$\log(u/(1-u))$	<code>qlogis(runif(n))</code>
Weibull(k, λ)	$\lambda(-\log(1-u))^{1/k}$	<code>lam*(-log(runif(n)))^(1/k)</code>
Pareto(x_m, α)	$x_m(1-u)^{-1/\alpha}$	<code>xm*runif(n)^(-1/alpha)</code>

Exp(2), $n = 10,000$: 표본평균 0.4956 (이론 0.5), 표본분산 0.2413 (이론 0.25). $1 - U \sim \text{Unif}(0,1)$ 이므로 $-\log U$ 를 써도 됨.



예제 2: 이산분포 — 일반화된 역함수



u 를 가로로 그어 처음 만나는 계단의 x 가 표본

$$X = x_j \quad \text{if} \quad F(x_{j-1}) < U \leq F(x_j)$$

$$P(X = 0, 1, 2, 3) = (0.1, 0.3, 0.4, 0.2)$$

x	0	1	2	3
$P(X = x)$	0.1	0.3	0.4	0.2
상대도수 ($n = 10^4$)	0.1031	0.2988	0.3995	0.1986

- $u = 0.55$ 는 $F(1) = 0.4 < u \leq F(2) = 0.8$ 이므로 $X = 2$
- R: `findInterval(u, cumsum(p)) + 1` 로 벡터화
- 확률이 큰 값부터 비교하면 평균 비교 횟수 감소 (값이 많을 때)

예제 3: 절단분포, 그리고 방법의 한계

$$X = F^{-1}\left(F(a) + U[F(b) - F(a)]\right) \sim F \text{ truncated to } (a, b)$$

절단 정규분포 $N(0,1)$ on $(1, 3)$

- U 를 $(F(a), F(b))$ 구간으로 줄여서 역변환 $\rightarrow$ 버리는 표본이 없음
- $n = 10,000$: 표본평균 1.5075 (이론 1.5100), 최솟값 1.0000, 최댓값 2.9991
- " 정규분포에서 뽑고 $(1,3)$ 밖이면 버리기 " 는 수락률 $P(1 < Z < 3) \approx 0.157$ 로 비효율
- EM 강의의 MCEM(중도절단 데이터) 예제에서 사용한 방법

한계

- F^{-1} 가 닫힌 형태가 아니면 **수치적으로 풀어야 함** (정규, 감마, 베타: qnorm 등은 정교한 근사식)
- 정규분포는 Box-Muller 변환 등 다른 방법이 더 빠름
- 다변량 분포에는 바로 적용 불가 — 조건부 분포로 차례로 분해해야 함
- 밀도가 비정규화 (베이지 사후분포) 되어 있으면 F 자체를 모름 $\rightarrow$ **rejection sampling, SIR**

R 코드 : Inverse CDF 방법

```
## Exponential(rate = lambda):  $F^{-1}(u) = -\log(1 - u) / \lambda$ 
rexp_inv <- function(n, lambda) -log(1 - runif(n)) / lambda

## Cauchy(0, 1):  $F^{-1}(u) = \tan(\pi * (u - 1/2))$ 
rcauchy_inv <- function(n) tan(pi * (runif(n) - 0.5))

## Discrete: generalized inverse  $F^{-1}(u) = \min\{x : F(x) \geq u\}$ 
rdiscrete <- function(n, vals, prob) {
  cp <- cumsum(prob)
  vals[findInterval(runif(n), cp) + 1]
}

## Truncated normal on (a, b):  $F^{-1}(F(a) + U(F(b) - F(a)))$ 
rtnorm <- function(n, mu, sd, a, b) {
  Fa <- pnorm(a, mu, sd); Fb <- pnorm(b, mu, sd)
  qnorm(Fa + runif(n) * (Fb - Fa), mu, sd)
}

set.seed(4)
x <- rexp_inv(10000, lambda = 2)
c(mean = mean(x), var = var(x)) # theory: 0.5, 0.25
d <- rdiscrete(10000, vals = 0:3, prob = c(0.1, 0.3, 0.4, 0.2))
table(d) / 10000
t <- rtnorm(10000, 0, 1, a = 1, b = 3)
c(mean = mean(t), min = min(t), max = max(t))
```

출력

Exp(2): mean 0.4956, var 0.2413

이산 : 0.1031, 0.2988, 0.3995, 0.1986

절단정규 : mean 1.5075

실습

- rcauchy_inv 로 뽑은 표본의 running mean 그려 보기
- Weibull 역함수를 직접 구현해 rweibull 과 비교 (qqplot)

04

Rejection Sampling

f 를 덮는 envelope 에서 뽑고 , 확률적으로 받아들이거나 버린다


아이디어 : envelope 아래의 점을 균등하게

$$e(x) = \frac{g(x)}{\alpha} \geq f(x) \quad \forall x, \quad 0 < \alpha \leq 1$$

g: 표본을 쉽게 뽑을 수 있는 분포 (proposal), e: f를 덮는 envelope

- 1 $Y \sim g$ 를 뽑는다
- 2 $U \sim \text{Unif}(0, 1)$ 를 독립으로 뽑는다
- 3 $U \leq f(Y)/e(Y)$ 이면 $X=Y$ 수락, 아니면 버리고 1로

기하학적 의미 : $(Y, U \cdot e(Y))$ 는 envelope 아래에 균등하게 흩어진 점. 그중 f 아래의 점만 남기면 그 x 좌표는 f를 따른다.



왜 맞는가 ? 그리고 수락률

수락된 Y 의 분포함수 (f 가 정규화된 경우)

$$P(Y \leq y \mid \text{accept}) = \frac{\int_{-\infty}^y g(z) \frac{f(z)}{e(z)} dz}{\int_{-\infty}^{\infty} g(z) \frac{f(z)}{e(z)} dz} = \frac{\alpha \int_{-\infty}^y f(z) dz}{\alpha} = F(y)$$

수락 확률 = envelope 아래 면적 중 f 아래 면적의 비율

$$P(\text{accept}) = \int g(z) \frac{f(z)}{e(z)} dz = \alpha = \frac{\int f}{\int e}$$

정규화 상수를 몰라도 된다

$$q(x) = c f(x) \quad (c \text{ unknown}), \quad e(x) \geq q(x) \Rightarrow \text{accept if } U \leq q(Y)/e(Y)$$

→ 베이즈 사후분포 $\pi(\theta)L(\theta|x)$ 에 바로 적용 (예제 2)

좋은 envelope 의 조건


- 모든 x 에서 $e(x) \geq f(x)$ — 꼬리까지 덮어야 함
- g 에서 뽑기 쉬울 것
- f 에 가깝게 붙어 α 가 1 에 가까울 것

예제 1: Beta(2.7, 6.3) — Uniform envelope

$$f(x) = \text{Beta}(2.7, 6.3), \quad e(x) = M \cdot 1_{(0,1)}(x), \quad M = \sup_x f(x) = f\left(\frac{1.7}{7}\right)$$

항목	값
$M = \sup f$	2.6697
이론 수락률 $1/M$	0.3746
관측 수락률	0.3815
표본평균 (이론 0.3)	0.3007

- 가장 단순한 envelope: 밀도의 최댓값 높이의 직사각형
- 수락률 $\approx 37\%$: 표본 하나를 얻으려면 평균 $M \approx 2.7$ 번 시도
- 꼬리 ($x > 0.7$) 에서 대부분 버려짐 $\rightarrow$ 더 좋은 envelope (예: 적당한 Beta, 조각 함수) 로 개선 가능



예제 2: 베이지 사후분포 — prior 를 envelope 로

$$X_i \mid \lambda \stackrel{iid}{\sim} \text{Poisson}(\lambda), \quad \log \lambda \sim N(\log 4, 0.5^2)$$

데이터 $x = (8, 3, 4, 3, 1, 7, 2, 6, 2, 7)$, $n = 10$, $\bar{x} = 4.3$


핵심 관찰 : likelihood 는 MLE $\hat{\lambda} = \bar{x}$ 에서 최대

$$q(\lambda \mid x) = \pi(\lambda) L(\lambda \mid x) \leq \pi(\lambda) L(\hat{\lambda} \mid x) = e(\lambda), \quad \hat{\lambda} = \bar{x}$$

따라서 envelope $\propto$ prior: prior 에서 뽑고 , 다음 확률로 수락

$$\frac{q(Y)}{e(Y)} = \frac{L(Y \mid x)}{L(\hat{\lambda} \mid x)} = \exp \left\{ \sum x_i \log(Y/\hat{\lambda}) - n(Y - \hat{\lambda}) \right\}$$

사후분포의 정규화 상수 $\int \pi(\lambda)L(\lambda|x)d\lambda$ 는 전혀 필요 없음




envelope 는 $\hat{\lambda}$ 에서만 q 에 닿는다


예제 2 결과 : 사후분포 요약

	수치적분 (참값)	Rejection ($n = 10^4$)
사후평균 $E[\lambda x]$	4.277	4.284
2.5% 분위수	3.144	3.170
97.5% 분위수	5.591	5.587
수락률	$\int q/\int e = 0.290$	0.290

- 수락된 λ 들이 곧 사후분포의 iid 표본 $\rightarrow$ 평균, 분위수, $P(\lambda > 5 | x)$ 등을 표본으로 계산
- 수락률 29% = **prior 에 비해 likelihood 가 얼마나 집중되어 있는가**
- 데이터가 많아지면 사후분포가 좁아져 수락률 $\downarrow$ (prior envelope 의 약점) $\rightarrow$ SIR 나 MCMC 로



Squeezed rejection 과 Adaptive Rejection Sampling



log N(0,1) 밀도, knot 4 개

Squeeze: f 계산이 비쌀 때

$$s(x) \leq f(x) \leq e(x) : \quad U \leq \frac{s(Y)}{e(Y)} \Rightarrow \text{accept (no evaluation of } f)$$

$U \leq s(Y)/e(Y)$ 에서 이미 수락되면 $f(Y)$ 를 계산하지 않음 . 아니면 일반 판정 .

ARS (Gilks & Wild, 1992)

- $\log f$ 가 오목 (log-concave) 이면 접선들이 위 , 현들이 아래를 덮음
- $\exp(\text{접선}) = \text{조각별 지수분포} \rightarrow \text{뽑기 쉬움}$
- 기각된 점을 새 knot 으로 추가해 envelope 가 점점 f 에 밀착
- Gibbs sampler (BUGS) 의 기본 도구

R 코드 (1): Beta 분포

```
## Target f: Beta(2.7, 6.3), envelope e(x) = M * g(x), g = Unif(0,1)
f <- function(x) dbeta(x, 2.7, 6.3)
M <- optimize(f, c(0, 1), maximum = TRUE)$objective # sup f(x)

rej_beta <- function(n) {
  out <- numeric(0); tries <- 0
  while (length(out) < n) {
    y <- runif(n) # 1. Y ~ g
    u <- runif(n) # 2. U ~ Unif(0,1)
    out <- c(out, y[u <= f(y) / M]) # 3. accept if U <= f(Y)/e(Y)
    tries <- tries + n
  }
  list(x = out[1:n], acc.rate = length(out) / tries)
}
set.seed(5)
r <- rej_beta(10000)
c(M = M, theory = 1 / M, acc.rate = r$acc.rate,
  mean = mean(r$x), true.mean = 2.7 / 9)
```

구현 요령

- 한 번에 n 개씩 제안해 벡터로 판정 (R 에서 루프보다 빠름)
- tries 로 실제 수락률을 기록
- M 은 optimize() 로 수치적으로 구함

출력 : $M = 2.6697$, $1/M = 0.3746$, 수락률 = 0.3815, 표본평균 = 0.3007

R 코드 (2): 베이즈 사후분포

```
## Poisson data, lognormal prior: log(lambda) ~ N(log 4, 0.5^2)
x <- c(8, 3, 4, 3, 1, 7, 2, 6, 2, 7)
logL <- function(lam) sum(x) * log(lam) - length(x) * lam # log L + const
lam.hat <- mean(x) # MLE maximizes L(lambda | x)

## q(lam) = prior(lam) * L(lam) <= prior(lam) * L(lam.hat) = e(lam)
rej_post <- function(n) {
  out <- numeric(0); tries <- 0
  while (length(out) < n) {
    y <- exp(rnorm(n, log(4), 0.5)) # Y ~ prior
    u <- runif(n)
    keep <- u <= exp(logL(y) - logL(lam.hat)) # q(Y)/e(Y) = L(Y)/L(lam.hat)
    out <- c(out, y[keep]); tries <- tries + n
  }
  list(lambda = out[1:n], acc.rate = length(out) / tries)
}
set.seed(7)
r <- rej_post(10000)
c(acc.rate = r$acc.rate, post.mean = mean(r$lambda),
  quantile(r$lambda, c(0.025, 0.975)))
```

구현 요령

- likelihood 비율은 log 스케일에서 계산 후 exp (underflow 방지)
- log L의 상수항 ($-\sum \log x_i!$)은 비율에서 상쇄되므로 생략
- prior 표본: $\exp(\text{rnorm}(n, \log 4, 0.5))$

출력: 수락률 0.290, 사후평균 4.284, 95% 구간 (3.170, 5.587)

05

Sampling Importance Resampling (SIR)


envelope 없이 : 가중치를 매기고 다시 뽑는다 (Rubin, 1987, 1988)

SIR 알고리즘

- 1 $Y_1, \dots, Y_m \sim g$ 를 iid 로 뽑는다 (m 은 크게)
- 2 표준화된 importance weight 계산
- 3 $\{Y_1, \dots, Y_m\}$ 에서 확률 $\tilde{w}_i$ 로 n 개를 재표본 $\rightarrow X_1, \dots, X_n$

$$w(Y_i) = \frac{f(Y_i)}{g(Y_i)}, \quad \tilde{w}_i = \frac{w(Y_i)}{\sum_{j=1}^m w(Y_j)}$$

f 는 상수배까지만 알아도 됨 (표준화에서 상쇄)



왜 맞는가 ? 그리고 주의점

재표본된 X 의 분포함수 ($m \rightarrow \infty$)

$$P(X \leq x) = \sum_{i=1}^m \tilde{w}_i I(Y_i \leq x) \xrightarrow{m \rightarrow \infty} \frac{E_g[w(Y)I(Y \leq x)]}{E_g[w(Y)]} = \int_{-\infty}^x f(z) dz$$

Rejection 과의 차이

- envelope 상수 ($\sup f/g$)를 몰라도 됨
- 결과는 **근사**: 유한한 m 에서는 f 와 정확히 같지 않음
- m/n 을 충분히 크게 (예: 10-20 배 이상)
- 재표본은 복원 / 비복원 모두 가능 ; 같은 값이 여러 번 뽑힐 수 있음


가중치 퇴화 (weight degeneracy)

$$ESS = \frac{1}{\sum_{i=1}^m \tilde{w}_i^2} \quad (1 \leq ESS \leq m)$$

- 소수의 Y_i 가 가중치를 독차지하면 ESS가 작아지고 재표본이 몇 개 값의 반복이 됨
- g 는 f 보다 꼬리가 두꺼워야 함 (f/g 가 유계)
- g 의 support가 f 의 support를 포함해야 함

예제 1: slash 분포 — proposal 의 꼬리가 중요하다

$$Y = \frac{Z}{U}, \quad Z \sim N(0, 1) \perp U \sim \text{Unif}(0, 1), \quad f(y) = \frac{1 - e^{-y^2/2}}{y^2 \sqrt{2\pi}} \quad (y \neq 0)$$



교훈

- 정규 proposal 은 $|y| > 4$ 인 값을 거의 만들지 못함 → 재표본이 slash 의 두꺼운 꼬리를 절대 재현하지 못함
- 히스토그램이 ± 4 에서 뚝 끊기고, 끝에 몇 개 값이 반복됨
- 반대로 꼬리가 두꺼운 slash 를 g 로 쓰면 $N(0,1)$ 을 잘 재현
- ESS 만 보고 안심하면 안 됨 : 없는 영역은 가중치로도 복구 불가

$m = 100,000, n = 5,000$	ESS	99% 분위수	참값
✗ target slash, $g = N(0,1)$	6,792	3.75	39.9
✓ target $N(0,1)$, $g = \text{slash}$	62,044	2.30	2.33


예제 2: 같은 사후분포를 SIR 로

$$g = \pi(\lambda) \implies w(Y_i) \propto \frac{\pi(Y_i)L(Y_i | x)}{\pi(Y_i)} = L(Y_i | x)$$

prior 에서 $m = 100,000$ 개 $\rightarrow$ 가중치는 likelihood $\rightarrow n = 5,000$ 개 대표본

	참값	Rejection	SIR
사후평균	4.277	4.284	4.266
2.5%	3.144	3.170	3.124
97.5%	5.591	5.587	5.615
비용		34,486 회 제안	$m = 100,000$

ESS = 40,220 / 100,000. 두 방법 모두 참값과 잘 일치 — SIR 은 envelope 상수 $L(\hat{\lambda})$ 가 필요 없다는 점이 다름.



R 코드 (1): SIR 함수와 slash 예제

```
## Sampling Importance Resampling (Rubin, 1987)
sir <- function(n, m, rg, dg, df) {
  y <- rg(m)                                # 1.  $Y_1..Y_m \sim g$ 
  w <- df(y) / dg(y)                        # 2. importance weights
  w <- w / sum(w)                          # standardized
  x <- sample(y, n, replace = TRUE, prob = w) # 3. resample n values
  list(x = x, ess = 1 / sum(w^2))          # effective sample size
}

## Slash distribution:  $Y = Z / U$ ,  $Z \sim N(0,1)$ ,  $U \sim \text{Unif}(0,1)$ 
dslash <- function(y) ifelse(y == 0, 1 / (2 * sqrt(2 * pi)),
                             (1 - exp(-y^2 / 2)) / (y^2 * sqrt(2 * pi)))
rslash <- function(n) rnorm(n) / runif(n)

set.seed(8)
bad <- sir(5000, 100000, rnorm, dnorm, dslash) # target slash,  $g = N(0,1)$ 
good <- sir(5000, 100000, rslash, dslash, dnorm) # target  $N(0,1)$ ,  $g = \text{slash}$ 
c(ess.bad = bad$ess, ess.good = good$ess)
quantile(bad$x, c(0.01, 0.99)) # slash: very heavy tails (true ~ +-40)
quantile(good$x, c(0.01, 0.99)) #  $N(0,1)$ : +-2.33
```

포인트

- `sample(..., prob = w)` 가 재표본 단계
- `sir()` 는 target/proposal 밀도만 바꾸면 재사용 가능
- $ESS = 1/\Sigma \tilde{w}^2$ 를 항상 확인

출력 : ESS 6,792 (bad) vs 62,044 (good); 99% 분위수 3.75 (bad, 참값 ≈ 39.9) vs 2.30 (good, 참값 2.33)

R 코드 (2): 사후분포의 SIR

```
## SIR for the same posterior: g = prior, weights = likelihood
x <- c(8, 3, 4, 3, 1, 7, 2, 6, 2, 7)
logL <- function(lam) sum(x) * log(lam) - length(x) * lam
set.seed(9)
m <- 100000; n <- 5000
y <- exp(rnorm(m, log(4), 0.5))      # Y_i ~ prior
lw <- logL(y)                       # log weights (prior cancels)
w <- exp(lw - max(lw)); w <- w / sum(w) # stable standardization
lam <- sample(y, n, replace = TRUE, prob = w)
c(ess = 1 / sum(w^2), post.mean = mean(lam),
  quantile(lam, c(0.025, 0.975)))
```

포인트

- prior 가 proposal 이면
가중치 = likelihood
- log 가중치에서 max 를 빼고
exp (underflow 방지)

출력 : ESS 40,220, 사후평균 4.266, 95% 구간 (3.124, 5.615)

실습 : 데이터를 10 배로 늘리면 (x 를 10 번 반복) 사후분포가 좁아진다 . 이때 rejection 의 수락률과 SIR 의 ESS 가 어떻게 변하는지 확인해 보자 .

정리 : 세 가지 난수 생성 방법

	Inverse CDF	Rejection sampling	SIR
필요한 것	F^{-1} (닫힌 형태 또는 수치)	비정규화 밀도 q + envelope $e \geq q$	비정규화 밀도 q + proposal g
결과	정확 (exact)	정확 (exact)	근사 ($m \rightarrow \infty$ 에서 정확)
효율	표본 1 개 = U 1 개	수락률 $\alpha = \int q / \int e$	ESS, m/n
약점	다변량 · 비정규화 밀도에 부적합	$\sup q/g$ 를 알아야 함 , 고차원에서 $\alpha \downarrow$	가중치 퇴화 , g 의 꼬리가 얇으면 실패
예제	Exponential, 이산 , 절단정규	Beta, Poisson-lognormal 사후분포	slash, 같은 사후분포

다음 : 분산감소 기법 (importance sampling, antithetic, control variates) → MCMC

References

Givens & Hoeting (2013). Computational Statistics, 2nd ed., Ch. 6. · Robert & Casella (2004). Monte Carlo Statistical Methods, 2nd ed.
 Devroye (1986). Non-Uniform Random Variate Generation. · Metropolis & Ulam (1949), JASA 44, 335–341.
 Rubin (1987), JASA 82, 543–546; (1988) Bayesian Statistics 3. · Gilks & Wild (1992), Applied Statistics 41, 337–348.