

Variance Reduction

Monte Carlo 분산감소 기법

Importance Sampling · Antithetic Sampling · Control Variates · Rao-Blackwellization

교재 : Givens & Hoeting, Computational Statistics, 2nd ed., Section 6.4

왜 분산감소인가 ?

MC 오차는 $\sigma/\sqrt{n}$. n 을 늘리는 대신 같은 n 에서 σ 를 줄인다 .

$$\mu = E_f[h(X)], \quad \hat{\mu}_{MC} = \frac{1}{n} \sum_{i=1}^n h(X_i), \quad \text{Var}(\hat{\mu}_{MC}) = \frac{\sigma^2}{n}$$

IS

Importance Sampling

표본을 중요한 영역에서 뽑고 가중치로 보정
예제 : 꼬리확률 , 희귀사건 (network failure)

AS

Antithetic Sampling

음의 상관을 갖는 쌍 $(U, 1-U)$ 을 평균
예제 : h 가 단조일 때 ; 구현상 제약 많음

CV

Control Variates

기댓값을 아는 $c(X)$ 로 오차를 상쇄
예제 : 적분 , Asian option

RB

Rao-Blackwellization

일부를 조건부 기댓값으로 계산해 대입
예제 : t 꼬리확률 , compound Poisson

01

Importance Sampling

중요한 곳에서 뽑고 , 가중치 f/g 로 보정한다

개념 : 측도를 바꾸고 가중치로 보정

$$\mu = \int h(x) f(x) dx = \int h(x) \frac{f(x)}{g(x)} g(x) dx = E_g[h(X) w(X)], \quad w(x) = \frac{f(x)}{g(x)}$$

$$\hat{\mu}_{IS} = \frac{1}{n} \sum_{i=1}^n h(X_i) w(X_i), \quad X_i \stackrel{iid}{\sim} g$$

$$\text{Var}(\hat{\mu}_{IS}) = \frac{1}{n} \left(E_g[h(X)^2 w(X)^2] - \mu^2 \right)$$

좋은 g 의 조건

$$g^*(x) = \frac{|h(x)| f(x)}{\int |h(z)| f(z) dz} \quad (h \geq 0 \Rightarrow \text{Var} = 0)$$


g^* 는 μ 를 알아야 하므로 불가능 $\rightarrow |h|f$ 와 모양이 비슷하고, f 보다 꼬리가 두꺼운 g 를 고른다 (w 가 유계).

f 를 상수배까지만 알 때 : 표준화 가중치

$$\hat{\mu}_{IS}^* = \frac{\sum_i h(X_i) w(X_i)}{\sum_i w(X_i)} \quad (f \text{ known up to a constant; biased but consistent})$$

베이즈 사후분포에 사용. SIR 의 가중치와 같은 형태 (지난 강의).

예제 1: 정규분포의 꼬리확률 $P(Z > 4.5)$




$$w(x) = \frac{\phi(x)}{\phi(x - 4.5)} = \exp\left(-4.5x + \frac{4.5^2}{2}\right)$$

$n = 100,000$	추정값	SE
Naive MC	0	0
IS, $g = N(4.5, 1)$	3.40×10^{-6}	2.42×10^{-8}
참값 $1 - \Phi(4.5)$	3.40×10^{-6}	

- naive: 10 만 개 중 4.5 를 넘는 값이 하나도 없음 → 추정값 0, SE 도 0 (의미 없음)
- IS: 절반 정도가 $\{x > 4.5\}$ 에 떨어지고 작은 가중치로 보정
- 분산 비 $\approx 57,829$ 배 : naive 로 같은 SE 를 얻으려면 $n \approx 5.8 \times 10^9$

예제 2: Network failure 확률



- 20 개의 edge 가 각각 독립적으로 확률 $p = 0.05$ 로 끊김
- $h(X) = 1$: A 와 B 가 연결되지 않음 (network failure)
- $b(X)$ = 끊긴 edge 수 . 최소 4 개가 끊겨야 실패 $\rightarrow$ 희귀사건

$$\mu = P(h(X) = 1) = \sum_{x \in \{0,1\}^{20}} h(x) p^{b(x)} (1-p)^{20-b(x)}, \quad p = 0.05$$


IS: 더 큰 고장확률 p^* 로 시뮬레이션하고 가중치로 보정

$$w(x) = \frac{p^{b(x)} (1-p)^{20-b(x)}}{p^{*b(x)} (1-p^*)^{20-b(x)}} = \left(\frac{p}{p^*}\right)^{b(x)} \left(\frac{1-p}{1-p^*}\right)^{20-b(x)}$$

참값 ($2^{20} = 1,048,576$ 가지를 모두 계산): $\mu = 1.337 \times 10^{-5}$

수업에서 다룬 network 구조 (edge 번호는 코드와 동일)

Network failure: p^* 의 선택



p^*	추정값	SE
0.05 (naive)	2.00×10^{-5}	1.41×10^{-5}
0.10	1.84×10^{-5}	4.44×10^{-6}
0.20	1.24×10^{-5}	1.82×10^{-6}
0.25	1.16×10^{-5}	1.76×10^{-6}
0.30	1.40×10^{-5}	2.63×10^{-6}
0.40	1.24×10^{-5}	4.01×10^{-6}

- naive MC ($n = 10^5$): 실패가 몇 번만 관측되어 $SE \approx 1.2 \times 10^{-5}$ (상대오차 약 90%)
- 최적 $p^* \approx 0.21$ 에서 $SE \approx 2.0 \times 10^{-6} \rightarrow$ 분산 약 33 배 감소
- p^* 를 너무 키우면 가중치 $(p/p^*)^b$ 가 너무 작아져 다시 나빠짐

R 코드 : 꼬리확률

```
## mu = P(Z > 4.5), Z ~ N(0,1)      true: 1 - pnorm(4.5) = 3.398e-06
set.seed(1)
n <- 100000
## (a) naive Monte Carlo
z <- rnorm(n)
h <- as.numeric(z > 4.5)
c(naive = mean(h), se = sd(h) / sqrt(n))

## (b) importance sampling with g = N(4.5, 1)
x <- rnorm(n, mean = 4.5)
w <- dnorm(x) / dnorm(x, mean = 4.5)      # w = f/g = exp(-4.5 x + 4.5^2/2)
hw <- (x > 4.5) * w
c(IS = mean(hw), se = sd(hw) / sqrt(n), true = pnorm(4.5, lower.tail = FALSE))
```

포인트

- naive 와 IS 를 같은 n 으로 비교
- $w = \text{dnorm}(x) / \text{dnorm}(x, 4.5)$
- hw 의 표준편차로 SE 계산

출력 : naive 0 (SE 0); IS 3.40×10^{-6} (SE 2.42×10^{-8}); 참값 3.40×10^{-6}

R 코드 : Network failure

```
## Network: A - a1..a4 - b1..b4 - B, 20 edges, each edge fails w.p. p = 0.05
## nodes: 1 = A, 2:5 = a1..a4, 6:9 = b1..b4, 10 = B
edges <- rbind(cbind(1, 2:5),      # 1-4 : A - a_i
               cbind(2:4, 3:5),    # 5-7 : a_i - a_(i+1)
               cbind(2:5, 6:9),    # 8-11 : a_i - b_i
               c(2, 7), c(5, 8),   # 12-13 : a1 - b2, a4 - b3
               cbind(6:8, 7:9),    # 14-16 : b_i - b_(i+1)
               cbind(6:9, 10))     # 17-20 : b_i - B

## h(x) = 1 if A and B are NOT connected; X: n x 20 matrix, 1 = edge works
h_net <- function(X) {
  reach <- matrix(FALSE, nrow(X), 10); reach[, 1] <- TRUE
  repeat {
    old <- reach
    for (k in 1:20) {
      u <- edges[k, 1]; v <- edges[k, 2]
      ok <- X[, k] == 1 & (reach[, u] | reach[, v])
      reach[ok, u] <- TRUE; reach[ok, v] <- TRUE
    }
    if (all(reach == old)) break
  }
  as.numeric(!reach[, 10])
}

## Importance sampling: simulate with failure prob p.star, reweight
net_is <- function(n, p = 0.05, p.star = 0.25) {
  B <- matrix(rbinom(n * 20, 1, p.star), n, 20) # 1 = broken
  b <- rowSums(B) # number of broken edges
  w <- (p / p.star)^b * ((1 - p) / (1 - p.star))^(20 - b)
  hw <- h_net(1 - B) * w
  c(est = mean(hw), se = sd(hw) / sqrt(n))
}

set.seed(2)
net_is(100000, p.star = 0.05) # = naive Monte Carlo
net_is(100000, p.star = 0.25) # importance sampling
```

포인트

- h_net : A 에서 도달 가능한 node 를 반복 확장 (벡터화)
- B: 1 = 끊긴 edge, 가중치는 끊긴 edge 수 b 만의 함수
- $p.star = 0.05$ 면 naive MC 와 같음

02

Antithetic Sampling

음의 상관을 갖는 쌍을 만들어 평균한다

개념 : 음의 상관을 이용

$$\hat{\mu}_{AS} = \frac{1}{n} \sum_{i=1}^n \frac{h(X_i) + h(X'_i)}{2}, \quad X_i \stackrel{d}{=} X'_i \sim f$$

$$\text{Var}(\hat{\mu}_{AS}) = \frac{\sigma^2}{2n} (1 + \rho), \quad \rho = \text{Corr}(h(X), h(X'))$$

$$\frac{\text{Var}(\hat{\mu}_{MC}, 2n \text{ draws})}{\text{Var}(\hat{\mu}_{AS}, n \text{ pairs})} = \frac{1}{1 + \rho}$$

공정한 비교 : 쌍 하나는 h 를 2 번 계산하므로 naive 2n 개와 비교 . $\rho < 0$ 이어야 이득 , $\rho > 0$ 이면 오히려 손해 .

일반적 구성 : inverse CDF

$$X = F^{-1}(U), \quad X' = F^{-1}(1 - U), \quad U \sim \text{Unif}(0, 1)$$


$$h \text{ monotone} \implies \text{Cov}(h(F^{-1}(U)), h(F^{-1}(1 - U))) \leq 0$$

특수한 경우 : 대칭 분포

$$f \text{ symmetric about } m : \quad X' = 2m - X \quad (\text{e.g. } Z' = -Z)$$

대칭이면 F^{-1} 없이 반사만으로 쌍을 만들 수 있음

비대칭 분포에서도 가능한가 ? — inverse CDF 면 가능






- 대칭은 필요조건이 아님 : $X = F^{-1}(U)$, $X' = F^{-1}(1-U)$ 이면 X' 는 X 와 같은 분포이고, U 가 크면 X' 가 작아짐
- Gamma(2,1) 처럼 치우친 분포에서는 X 와 X' 가 평균에 대해 대칭이 아님 ($0.68 \leftrightarrow 3.37$) — 그래도 음의 상관
- 핵심 조건은 대칭이 아니라 $h \circ F^{-1}$ 가 단조인가

진짜 어려움 : F^{-1} 를 계산할 수 있는가

비대칭 분포는 대부분 F^{-1} 가 닫힌 형태가 아니라 수치적 역함수 (qgamma, qbeta ...) 가 필요 → 느리고, 다음 슬라이드의 제약이 따름

예제 : 효과가 있는 경우와 역효과가 나는 경우



$\mu = E[h(X)]$	$h \circ F^{-1}$ 단조 ?	ρ	효율 $1/(1+\rho)$	추정값 (SE)
$E[\exp(U^2)]$	예	-0.751	4.01 배	1.4642 (0.00075)
$E[\log(1+X)], X \sim \text{Gamma}(2,1)$	예 (비대칭 분포)	-0.993	140 배	0.9999 (0.00012)
$E[Z^2], Z \sim N(0,1)$	아니오 : $Z' = -Z$	+1.000	0.50 배 (손해)	1.0058 (0.00638)
$E[\cos(2\pi U)]$	아니오	+1.000	0.50 배 (손해)	-0.0031 (0.00316)

구현에서의 어려움 — 이론은 쉽지만 실제로는 제약이 많다

1 h 가 단조가 아니면 역효과

Z^2 처럼 대칭 구조를 가진 h 는 $h(X) = h(X') \rightarrow \rho = +1$, 분산 2 배 . h 의 형태를 미리 알아야 함

2 F^{-1} 가 필요

비대칭 분포는 수치적 역함수 : `qgamma` 는 `rgamma` 보다 약 10 배 느림 (10^6 개 : 0.09 초 vs 0.83 초)

3 Rejection · SIR · MCMC 표본과 결합 불가

표본 하나에 쓰이는 난수의 개수가 random 이라 $U \leftrightarrow 1-U$ 의 짝이 유지되지 않음

4 다변량

각 좌표를 $1-U_j$ 로 바꾸면 되지만 , h 가 모든 좌표에 대해 같은 방향으로 단조여야 음의 상관이 보장됨

5 변환으로 만든 난수

Box-Muller 등으로 생성하면 $(U_1, U_2) \rightarrow (1-U_1, 1-U_2)$ 가 단조 대응이 아님 . 정규는 대신 $Z' = -Z$ 사용

R 코드 : Antithetic sampling

```
## Antithetic pairs via inverse CDF:  $X = F^{-1}(U)$ ,  $X' = F^{-1}(1 - U)$ 
anti <- function(n, hq) {
  u <- runif(n)
  a <- hq(u); b <- hq(1 - u)
  rho <- cor(a, b)
  est <- mean((a + b) / 2)
  c(est = est, se = sd((a + b) / 2) / sqrt(n), rho = rho,
    efficiency = 1 / (1 + rho)) # vs. naive MC with 2n draws
}
set.seed(3)
n <- 50000
## (1) monotone h, uniform:  $E[\exp(U^2)]$ 
anti(n, function(u) exp(u^2))
## (2) monotone h, skewed Gamma(2,1) (not symmetric!):  $E[\log(1 + X)]$ 
anti(n, function(u) log(1 + qgamma(u, shape = 2)))
## (3) non-monotone h:  $E[Z^2]$  with  $Z = \text{qnorm}(U) \rightarrow Z' = -Z$ , same h!
anti(n, function(u) qnorm(u)^2)
## (4) non-monotone h:  $E[\cos(2 \pi U)]$ 
anti(n, function(u) cos(2 * pi * u))

## cost of the inverse CDF for non-symmetric distributions
system.time(rgamma(1e6, shape = 2)) # fast (rejection-type method)
system.time(qgamma(runif(1e6), shape = 2)) # slow (numerical inversion)
```

포인트

- anti() 에는 $h(F^{-1}(u))$ 를 u 의 함수로 넘김
- efficiency = $1/(1+\rho)$: naive 2n 개 대비
- (3), (4) 는 일부러 실패하는 예

03

Control Variates

기댓값을 아는 변수와의 상관을 이용해 오차를 상쇄한다

개념

$$\hat{\mu}_{CV} = \hat{\mu}_{MC} + \lambda (\hat{\theta}_{MC} - \theta), \quad \theta = E[c(X)] \text{ known}$$

$$\text{Var}(\hat{\mu}_{CV}) = \frac{1}{n} \left(\sigma_h^2 + 2\lambda \text{Cov}(h, c) + \lambda^2 \sigma_c^2 \right)$$

$$\lambda^* = -\frac{\text{Cov}(h(X), c(X))}{\text{Var}(c(X))}, \quad \text{Var}(\hat{\mu}_{CV}^*) = \frac{\sigma_h^2}{n} (1 - \rho_{hc}^2)$$

λ^* 는 모르므로 같은 표본으로 추정 = 회귀분석

$$h(X_i) = \beta_0 + \beta_1 (c(X_i) - \theta) + \varepsilon_i \implies \hat{\mu}_{CV} = \hat{\beta}_0, \quad \hat{\lambda} = -\hat{\beta}_1$$


$|\rho|$ 가 1에 가까운 $c(X)$ 를 찾는 것이 핵심 ($\rho = 0.9 \rightarrow$ 분산 81% 감소, $\rho = 0.99 \rightarrow 98\%$). 여러 개의 control variate 도 다중회귀로 동시에 사용 가능.

예제 1: $\int_0^1 \exp(x^2) dx$ 와 Taylor 근사

$$h(U) = e^{U^2}, \quad c(U) = 1 + U^2, \quad \theta = E[c(U)] = 4/3$$

n = 10,000	추정값	SE
Naive MC	1.46000	0.00470
Control variate	1.46194	0.00061
참값	1.46265	

- $\rho(h, c) = 0.9916$, $\hat{\lambda} = -1.573$
- 분산 비 = $(SE \text{ 비})^2 \approx 60 \text{ 배} \rightarrow$ 같은 정확도에 필요한 n 이 약 1/60
- $c(U) = 1 + U^2$ 는 e^{U^2} 의 1 차 Taylor 근사: h 와 비슷하게 움직이고 기댓값을 알




예제 2: Arithmetic Asian option — geometric Asian 을 control 로

$$\text{payoff} = e^{-rT} \left(\frac{1}{m} \sum_{j=1}^m S_{t_j} - K \right)^+, \quad \text{control: } e^{-rT} \left(\left(\prod_{j=1}^m S_{t_j} \right)^{1/m} - K \right)^+$$

$$\log G \sim N \left(\log S_0 + \left(r - \frac{\sigma^2}{2} \right) \frac{T(m+1)}{2m}, \sigma^2 \frac{T(m+1)(2m+1)}{6m^2} \right) \Rightarrow \theta \text{ in closed form}$$

n = 10,000 paths	가격	SE
Naive MC	8.431	0.1267
Control variate	8.475	0.0052

- $S_0 = K = 100, r = 0.05, \sigma = 0.3, T = 1 \text{ 년}, m = 12$ (월별 평균)
- arithmetic 평균의 분포는 닫힌 형태가 없지만 geometric 평균은 lognormal $\rightarrow$ 가격이 공식으로 나옴
- $\rho = 0.9992 \rightarrow$ 분산 약 603 배 감소
- control 의 MC 평균 7.983 vs 정확한 값 8.025: 이 차이만큼 보정



R 코드 : Control variates

```
## (1) mu = E[exp(U^2)], control variate c(U) = 1 + U^2, E[c(U)] = 4/3
set.seed(4)
n <- 10000
u <- runif(n)
h <- exp(u^2); cc <- 1 + u^2
lam <- -cov(h, cc) / var(cc) # estimated optimal lambda
cv <- h + lam * (cc - 4/3)
c(naive = mean(h), se.naive = sd(h) / sqrt(n),
  CV = mean(cv), se.CV = sd(cv) / sqrt(n), lambda = lam, rho = cor(h, cc))
## same thing as regression: coef(lm(h ~ I(cc - 4/3)))[1]

## (2) Arithmetic Asian call option; control = geometric Asian call
S0 <- 100; K <- 100; r <- 0.05; sig <- 0.3; T <- 1; m <- 12
dt <- T / m
geo_price <- function() { # closed form (lognormal)
  mu.G <- log(S0) + (r - sig^2 / 2) * T * (m + 1) / (2 * m)
  s.G <- sig * sqrt(T * (m + 1) * (2 * m + 1) / (6 * m^2))
  d2 <- (mu.G - log(K)) / s.G; d1 <- d2 + s.G
  exp(-r * T) * (exp(mu.G + s.G^2 / 2) * pnorm(d1) - K * pnorm(d2))
}
Z <- matrix(rnorm(n * m), n, m)
logS <- log(S0) + t(apply((r - sig^2 / 2) * dt + sig * sqrt(dt) * Z, 1, cumsum))
S <- exp(logS) # n x m price paths
ari <- exp(-r * T) * pmax(rowMeans(S) - K, 0) # target payoff
geo <- exp(-r * T) * pmax(exp(rowMeans(logS)) - K, 0) # control
lam <- -cov(ari, geo) / var(geo)
cv <- ari + lam * (geo - geo_price())
c(naive = mean(ari), se.naive = sd(ari) / sqrt(n),
  CV = mean(cv), se.CV = sd(cv) / sqrt(n), lambda = lam, rho = cor(ari, geo))
```

포인트

- $\hat{\lambda} = -\text{cov}/\text{var}$ 는 $\text{lm}(h \sim c)$ 의 기울기와 같음
- `geo_price()`: geometric Asian 의 closed form
- Finance case study (Option 가격 결정) 와 연결

04

Rao-Blackwellization

계산할 수 있는 부분은 조건부 기댓값으로 정확히 계산한다

개념 : 조건부 기댓값으로 바꾸면 분산이 줄어든다

$$\mu = E[h(X)] = E[E[h(X) | Y]]$$

$$\hat{\mu}_{RB} = \frac{1}{n} \sum_{i=1}^n E[h(X) | Y_i]$$

분산 분해 (law of total variance)

$$\text{Var}(h(X)) = \underbrace{\text{Var}(E[h(X) | Y])}_{\text{RB variance}} + \underbrace{E[\text{Var}(h(X) | Y)]}_{\geq 0 \text{ removed}}$$

아이디어


- X 를 만드는 과정에 보조변수 Y 가 있고
- Y 가 주어지면 $E[h(X) | Y]$ 를 계산할 수 있다면
- X 를 뽑지 말고 조건부 기댓값을 대입 → 편향 없이 분산 감소

이름의 유래와 주의점

- Rao-Blackwell 정리 : 충분통계량에 대한 조건부 기댓값은 분산을 줄임
- 적용하려면 $E[h | Y]$ 가 닫힌 형태 또는 싼 계산이어야 함
- MCMC(Gibbs) 에서 조건부 평균으로 흔히 사용

예제 1: t 분포의 꼬리확률 $P(T > 3)$, $\nu = 5$


$$T = \frac{Z}{\sqrt{V/\nu}}, \quad Z \sim N(0, 1) \perp V \sim \chi_\nu^2 : \quad E[I(T > 3) | V] = 1 - \Phi(3\sqrt{V/\nu})$$



n = 10,000	추정값	SE	참값 pt(3, 5, lower = FALSE)
Naive: $I(T > 3)$	0.01550	0.00124	0.01505
Rao-Blackwellized	0.01490	0.00030	분산 약 17 배 감소

예제 2: 보험 총손해액 (compound Poisson)

$$S = \sum_{j=1}^N X_j, \quad N \sim \text{Poisson}(5), \quad X_j \stackrel{iid}{\sim} \text{Exp}(1) : \quad E[I(S > 12) \mid N] = P(\text{Gamma}(N, 1) > 12)$$



n = 10,000	추정값	SE
Naive: $I(S > 12)$	0.0338	0.00181
Rao-Blackwellized	0.0320	0.00066
참값 (급수 계산)	0.0311	

- 청구 건수 N 만 시뮬레이션 : 개별 청구액 X_j 를 뽑을 필요가 없음 (계산도 더 빠름)
- N 이 주어지면 $S \sim \text{Gamma}(N, 1) \rightarrow$ 조건부 확률은 `pgamma`
- 분산 약 7.4 배 감소

R 코드 : Rao-Blackwellization

```
## (1) t tail probability P(T > 3), T = Z / sqrt(V / nu), V ~ chi^2_nu
## Rao-Blackwell: E[ I(T > 3) | V ] = 1 - Phi(3 * sqrt(V / nu))
set.seed(5)
n <- 10000; nu <- 5
V <- rchisq(n, df = nu); Z <- rnorm(n)
h.naive <- as.numeric(Z / sqrt(V / nu) > 3)
h.rb <- pnorm(3 * sqrt(V / nu), lower.tail = FALSE)
c(naive = mean(h.naive), se = sd(h.naive) / sqrt(n),
  RB = mean(h.rb), se.RB = sd(h.rb) / sqrt(n),
  true = pt(3, nu, lower.tail = FALSE))

## (2) Compound Poisson (aggregate claims): S = X_1 + ... + X_N,
## N ~ Poisson(5), X_j ~ Exp(1). Estimate P(S > 12).
## Rao-Blackwell: S | N ~ Gamma(N, 1) -> E[I(S > 12) | N] = P(Gamma(N,1) > 12)
N <- rpois(n, 5)
S <- sapply(N, function(k) sum(rexp(k)))
h.naive <- as.numeric(S > 12)
h.rb <- ifelse(N == 0, 0, pgamma(12, shape = pmax(N, 1), lower.tail = FALSE))
true <- sum(dpois(1:100, 5) * pgamma(12, 1:100, lower.tail = FALSE))
c(naive = mean(h.naive), se = sd(h.naive) / sqrt(n),
  RB = mean(h.rb), se.RB = sd(h.rb) / sqrt(n), true = true)
```

포인트

- naive 와 RB 는 같은 (V, Z) 또는 N 을 사용
- RB 에서는 Z, X_j 를 적분해 없앴
- N = 0 이면 S = 0 → 조건부 확률 0

정리 : 네 가지 분산감소 기법

	Importance Sampling	Antithetic	Control Variates	Rao-Blackwellization
핵심 아이디어	중요 영역에서 뽑고 f/g 로 보정	$\rho < 0$ 인 쌍을 평균	기댓값을 아는 $c(X)$ 로 보정	$E[h Y]$ 를 정확히 계산
필요 조건	g 에서 샘플링 , f/g 유계	F^{-1} 사용 , $h \circ F^{-1}$ 단조	$ \rho(h, c) $ 가 큰 c , $E[c]$ 알려짐	$E[h Y]$ 가 계산 가능
위험	꼬리 얇은 $g \rightarrow$ 무한 분산	h 가 비단조면 역효과	약한 상관이면 효과 없음	거의 없음 (편향 없음)
이번 예제의 분산 감소	57,829 배 (꼬리), 33 배 (network)	4.0 배 , 140 배 / 0.5 배	60 배 , 603 배	17 배 , 7.4 배

기법은 결합 가능 : 예) IS + control variate, antithetic + RB. 비교는 항상 같은 계산 비용 기준으로 .

References

Givens & Hoeting (2013). Computational Statistics, 2nd ed., Sec. 6.4. · Robert & Casella (2004). Monte Carlo Statistical Methods, 2nd ed., Ch. 3–4.
 Rubinstein & Kroese (2016). Simulation and the Monte Carlo Method, 3rd ed. · Glasserman (2003). Monte Carlo Methods in Financial Engineering, Ch. 4.